

NLP MENTAL HEALTH CONVERSATIONS

Compte-rendu technique

Étape 1 : Exploration du jeu de données

Projet : Analyse de conversations patient-thérapeute sur la santé mentale

Encadrante : Lynda Tamine-Lechani

Équipe :

*Ulysse Chasseigne, Idir Yahiaoui, Bantsoukissa Laure,
Cruz Fernandes Diogo, Emin Belkheir, Ezzo-Y-N Trésor PANA,
Logan Larroux, Yvan Sellier, Victor Blanquart-Blanchet, Lucas Da Silva*

19 avril 2026



[Info5.BE-SHS]

Données : [Kaggle](#) — NLP Mental Health Conversations

Code : [GitHub](#) — branche Logan

Table des matières

1	Introduction	2
2	Analyse statistique	2
2.1	Prétraitement des données	2
2.2	Résultats obtenus	3
2.3	Nombre de mots moyen par patient / thérapeute	4
3	Analyse lexicale — Mots les plus fréquents	4
3.1	Sans filtrage renforcé	4
3.2	Avec filtrage renforcé (stopwords personnalisés)	5
3.3	Interprétation	5
4	Topic Modeling — Méthode 1 : Lexique personnalisé	6
4.1	Principe	6
4.2	Résultats	7
4.3	Évaluation critique	8
5	Topic Modeling — Méthode 2 : TF-IDF + K-Means	8
5.1	Principe	8
5.2	Sélection du nombre de clusters (k)	8
5.3	Résultats comparés selon k	8
5.4	Évaluation critique	10
6	Topic Modeling — Méthode 3 : Word Embeddings	10
6.1	Word2Vec (Skip-gram) — Logan	10
6.2	Sentence Transformer (BERT / all-MiniLM-L6-v2) — Idir	11
6.3	spaCy (embeddings moyennés) — Emin	12
6.4	Bilan comparatif — Méthode 3	12
7	Topic Modeling — Méthode 4 : LDA	13
7.1	Principe	13
7.2	Résultats comparés	14
7.3	Évaluation critique	15
8	Conclusion comparée des méthodes	15
9	Problèmes rencontrés et questions ouvertes	16
9.1	Problèmes techniques identifiés	16
9.2	Questions ouvertes à soumettre à l'encadrante	16

1 Introduction

L'étape 1 a pour objectif d'explorer et de comprendre la structure du corpus de conversations patient-thérapeute issu du dataset Kaggle (**train.csv**). Le fichier contient deux colonnes : le message du patient (**Context**) et la réponse du thérapeute (**Response**).

Chaque membre de l'équipe a travaillé de façon **individuelle** sur ses propres scripts Python afin de pouvoir comparer les résultats et les approches ensuite en groupe. Cette démarche volontairement divergente permet d'identifier les biais liés aux choix de prétraitement et de paramétrage.

Remarque importante : Les prétraitements appliqués au texte ont un impact **direct et significatif** sur l'ensemble des résultats obtenus. La qualité du nettoyage (suppression des stopwords, normalisation, détection de la langue, filtrage des doublons) est donc un point critique qui explique la majorité des écarts observés entre les membres de l'équipe.

2 Analyse statistique

2.1 Prétraitement des données

Chaque membre a adopté une stratégie de nettoyage plus ou moins stricte. Voici deux exemples d'approches représentatives.

Approche minimaliste (Emin) — suppression des lignes vides uniquement :

```
# Suppression des lignes vides
df = df.dropna(how='all')
df = df.dropna(subset=['Context'])
df = df.dropna(subset=['Response'])
df = df.reset_index(drop=True)
```

Approche étendue (Diogo) — nettoyage complet avec détection de langue :

```
stop_words = set(stopwords.words('english'))

def clean_text(text):
    text = str(text).lower()
    text = re.sub(r"[\r\n]+", " ", text)
    text = re.sub(r"[^a-z0-9\s]", "", text)
    text = re.sub(r"\s+", " ", text)
    words = text.strip().split()
    words = [w for w in words if w not in stop_words]
    return " ".join(words)
```

```
def is_english(text):
    try:
        return detect(str(text)) == 'en'
    except:
        return False

# Pipeline de nettoyage complet
df = df.dropna(subset=["Response"])
df = df.drop_duplicates(subset=["Context", "Response"], keep="first")
df['Context'] = df['Context'].apply(clean_text)
df['Response'] = df['Response'].apply(clean_text)
mask = df['Context'].apply(is_english) & df['Response'].apply(is_english)
df = df[mask].reset_index(drop=True)
```

2.2 Résultats obtenus

Les divergences de prétraitement expliquent les écarts dans les résultats ci-dessous.

Nombre de patients uniques

Résultat	Membres	Méthode appliquée
995	8 personnes	Sans prétraitement — <code>nunique()</code> brut
819	1 personne	Prétraitement + filtre sur les mots espagnols
796	1 personne	Prétraitement + filtre sur les mots espagnols

Nombre de thérapeutes uniques

Résultat	Membres	Méthode appliquée
2 479	6 personnes	Sans prétraitement
2 472	1 personne	Léger prétraitement (suppression des retours à la ligne)
2 409	1 personne	Prétraitement complet
≥ 12	1 personne	Pattern matching (identification par motifs)

Limite importante : Les valeurs autour de 2 400–2 479 correspondent très probablement au **nombre de lignes/réponses** dans le fichier, et non au nombre réel de thérapeutes distincts. En l'absence d'identifiant unique (ID), il est impossible de différencier les thérapeutes entre eux avec certitude.

Question ouverte : Existe-t-il une technique fiable permettant de différencier patients et thérapeutes sans passer par un identifiant explicite ?

2.3 Nombre de mots moyen par patient / thérapeute

Ces chiffres sont **fortement impactés** par le niveau de prétraitement appliqué. Les membres ayant supprimé davantage de mots (stopwords, contractions, etc.) obtiennent naturellement des moyennes plus basses.

Côté patients

Membre	Mots moyens
Victor	66,86
Emin	55,2
Idir	24,8
Lucas	21,3
Logan	16,3

Côté thérapeutes

Membre	Mots moyens
Emin	177,2
Victor	140,2
Idir	84,8
Lucas	82,4
Logan	60,1

On observe un **rapport allant du simple au quadruple** selon le niveau de filtrage. Les thérapeutes produisent systématiquement des réponses bien plus longues que les messages des patients, ce qui est cohérent avec la nature de l'échange thérapeutique.

3 Analyse lexicale — Mots les plus fréquents

3.1 Sans filtrage renforcé

Côté patients	Côté thérapeutes	Global
<i>im, feel, dont</i>	<i>feel, may, help, like</i>	<i>feel, like, may</i>

Ces résultats, bien que représentatifs du corpus brut, sont peu exploitables : les mots les plus fréquents sont des **mots fonctionnels** ou des contractions sans valeur sémantique forte.

3.2 Avec filtrage renforcé (stopwords personnalisés)

Certains membres ont étendu la liste des stopwords pour exclure des mots peu informatifs mais non présents dans les listes standards :

```
# Exemple - Logan
```

```
extra_stopwords = {
    "feel", "like", "want", "know", "time",
    "thing", "good", "need", "year", "think",
    "tell", "say", "come", "go"
}
```

```
# Exemple - Lucas
```

```
mots_inutiles = set([
    "i", "me", "my", "myself", "we", "our", "ours", "ourselves",
    "you", "your", "yours", "yourself", "yourselves",
    "he", "him", "his", "himself", "she", "her", "hers", "herself",
    "it", "its", "itself", "they", "them", "their", "theirs", "themselves",
    # ... [liste complete dans le notebook]
    "feel", "really", "things", "just", "like", "very", "too", "lot",
    "there", "back", "even", "every", "years", "told", "going", "still"
])
```

Côté patients	Côté thérapeutes	Global
<i>relationship, love, anxiety</i>	<i>relationship, like</i>	<i>relationship, help</i>

3.3 Interprétation

Les deux niveaux de filtrage sont **complémentaires** et révèlent des niveaux d'information différents :

- **Sans filtrage renforcé** → on observe les **expressions émotionnelles** brutes des patients (*feel, love*) et la posture d'aide des thérapeutes (*may, help, would*).
- **Avec filtrage renforcé** → on accède aux **thématiques explicites** : *relationship, anxiety, love* côté patient ; *relationship* côté thérapeute.

Ces résultats confirment que le corpus est centré sur les **relations interpersonnelles**, sujet le plus fréquent, couplé à des états psychologiques comme l'anxiété.

Question ouverte : Existe-t-il une méthode automatique pour pondérer les mots selon leur pertinence sémantique, sans les supprimer manuellement ?

L'analyse lexicale donne ainsi une première image du corpus, ce dont les patients parlent et comment les thérapeutes leur répondent. Pour aller plus loin et identifier des **thématiques structurées** au sein de ces échanges, **quatre méthodes** de topic modeling ont été appliquées et comparées.

4 Topic Modeling — Méthode 1 : Lexique personnalisé

4.1 Principe

Un dictionnaire thématique est construit **manuellement**, en associant chaque thème de santé mentale à une liste de mots-clés. Chaque question peut être assignée à **plusieurs thèmes simultanément** (classification multi-label).

```
# Exemple - Tresor
lexique = {
    'Anxiete':      ['anxious', 'anxiety', 'panic', 'fear'],
    'Depression':  ['depress', 'depression', 'sad', 'suicide'],
    'Relation':     ['relationship', 'husband', 'wife', 'partner']
}

# Exemple - Diogo (version etendue)
LEXICON = {
    'Anxiety':      ['anxiety', 'anxious', 'panic', 'worry', 'worried', 'nervous', 'fear', 'phobia', 'stress', 'stressed', 'overthink', 'dread'],
    'Depression':  ['depression', 'depressed', 'sad', 'sadness', 'hopeless', 'empty', 'numb', 'unmotivated', 'despair', 'grief', 'miserable'],
    'Relationships': ['relationship', 'partner', 'boyfriend', 'girlfriend', 'husband', 'wife', 'marriage', 'divorce', 'breakup', 'couple', 'dating', 'love', 'trust'],
    'Family':      ['family', 'mother', 'father', 'parent', 'child', 'children', 'son', 'daughter', 'sister', 'brother'],
}
```

```

'Self-esteem': ['self-esteem', 'confidence', 'worthless', 'shame', 'guilt',
                'insecure', 'identity', 'self-worth', 'self-image', 'inadequate'],
'Suicidal':    ['suicide', 'suicidal', 'kill myself', 'end my life', 'self-harm',
                'cutting', 'hurt myself', 'die', 'death'],
'Addiction':   ['addiction', 'addicted', 'alcohol', 'drugs', 'substance',
                'drinking', 'smoking', 'marijuana', 'weed', 'cocaine', 'gambling'],
'Trauma/PTSD': ['trauma', 'ptsd', 'abuse', 'assault', 'flashback', 'nightmare',
                'violence', 'rape', 'harassment', 'survivor'],
'Sleep':       ['sleep', 'insomnia', 'tired', 'exhausted', 'fatigue', 'rest',
                'awake', 'sleepless'],
'Anger':        ['anger', 'angry', 'rage', 'furious', 'irritable', 'frustration',
                 'aggressive', 'temper'],
'Loneliness':  ['lonely', 'loneliness', 'alone', 'isolated', 'isolation',
                 'disconnected', 'friendless'],
'Work/School': ['work', 'job', 'career', 'school', 'college', 'university',
                 'boss', 'coworker', 'burnout', 'performance', 'exam', 'grades']
}

```

4.2 Résultats

Les thèmes apparaissant de façon **transversale** dans toutes les conversations sont :

- **Anxiété** (*anxiety, panic, stress*)
- **Dépression** (*depression, sad, hopeless*)
- **Relations** (*relationship, love, partner*) — thème le plus fréquent

Avoir le thème *Relation* comme le plus fréquent peut sembler logique au vu du contexte du Dataframe, mais cela ne veut pas dire qu'il n'existe pas d'autres thèmes bien plus importants et auxquels on ne penserait pas directement.

4.3 Évaluation critique

Avantage	Limite
Très interprétable et explicable	Rigide : ne capte que les mots explicitement listés
Facile à adapter au domaine	Ne gère pas les synonymes non prévus
Résultats stables et reproductibles	Nécessite une expertise métier pour construire le lexique
Classification multi-label naturelle	Insensible au contexte d'usage d'un mot

5 Topic Modeling — Méthode 2 : TF-IDF + K-Means

5.1 Principe

Chaque texte est transformé en un **vecteur numérique** via TF-IDF (Term Frequency–Inverse Document Frequency), où chaque dimension représente l'importance relative d'un mot dans un document par rapport à l'ensemble du corpus. Ces vecteurs sont ensuite regroupés par l'algorithme **K-Means**.

5.2 Sélection du nombre de clusters (k)

Le choix de k est délicat. Plusieurs stratégies ont été explorées :

- **Définition manuelle** : observation visuelle des clusters pour juger de leur pertinence.
- **Méthode du coude** (*elbow method*) : on trace l'inertie en fonction de k et on cherche le point de rupture.
- **Équilibrage des tailles** : minimiser les écarts de taille entre clusters.

La méthode du coude suggère $k = 6$, mais la courbe décroît faiblement à partir de ce point, ce qui rend le choix ambigu. Visuellement, $k = 4$ ou $k = 8$ seraient aussi défendables.

5.3 Résultats comparés selon k

$K = 6$ — Clusters déséquilibrés — Logan

Thème identifié	Effectif
Dépression sévère — idées suicidaires	457
Mal-être général — perte de motivation	112
Dépression sévère — fatigue mentale	46
Thérapie de couple — anxiété	223
Traumatisme — abus — maladie grave	1 718
Problèmes familiaux — divorce — identité	139

Résultat insuffisant : fort déséquilibre de taille (46 vs 1718), thèmes qui se recoupent.

$K = 5$ — Clusters partiellement pertinents — Emin

```
years - told - sex - time - back - child
im - dont - feel - know - like - want
therapy - normal - still - shaky - everytime - cry
decide - client - counselor - end - terminate - working
counseling - address - history - many - issues - process
```

Un cluster contient des mots peu informatifs, et les deux derniers sont trop similaires.

$K = 4$ — Clusters trop vagues — Victor

```
know, want, dont, years, get, relationship, sex, told, time, love
therapy, sessions, normal, still, counseling, cry, decide, client
, counselor, process
address, history, many, issues, counseling, ive, breast,
insomniac, lifetime, happily
feel, like, dont, people, really, know, always, get, anything,
cant
```

Trop peu précis : le 4^e cluster ne contient rien d'utile, les 2^e et 3^e ne se distinguent pas assez.

$K = 3$ — Meilleure configuration avec LSA

En appliquant une **décomposition LSA** (Latent Semantic Analysis via SVD) sur la matrice TF-IDF avant le clustering, et avec des hyperparamètres plus fins :

```
vec = TfidfVectorizer(
    max_features=10000,                # limite aux 10000
        termes les plus frequents
    ngram_range=(1, 3),                # unigrammes,
        bigrammes et trigrammes
    min_df=3,                          # ignore les mots trop
        rares
    max_df=0.5,                        # ignore les mots trop
        frequents
    sublinear_tf=True,                 # normalisation
        logarithmique
    stop_words=list(STOPWORDS),        # retire une liste de
        mots supplémentaire
```

```

strip_accents="unicode",          # normalise les
accents
token_pattern=r"(?u)\b[a-zA-Z]{2,}\b" # sequences
    alphabetiques >= 2 caracteres
)

```

Topic	Effectif	Part	Mots-clés principaux
Family and relational dynamics	309	38,8 %	friends, family, child, dad, mom, husband
Emotional distress and mental health	284	35,7 %	anxiety, depression, stop, start, school
Romantic relationships and intimacy	203	25,5 %	love, relationship, boyfriend, sex, girl

Meilleur résultat TF-IDF : thèmes distincts, tailles équilibrées, couvrant 100 % du corpus.

5.4 Évaluation critique

Avantage	Limite
Méthode rapide et scalable	Sensible au choix de k
Bien documentée et reproductible	Ignore la sémantique contextuelle des mots
Compatible avec LSA pour de meilleurs résultats	Mots traités comme des entités indépendantes

Question ouverte : Existe-t-il une méthode plus robuste que le coude pour déterminer automatiquement le nombre optimal de clusters ?

6 Topic Modeling — Méthode 3 : Word Embeddings

Le Word Embedding (plongement lexical) est une **représentation sémantique des mots** sous forme de **vecteurs** de nombres réels. Deux mots de sens proches ont des vecteurs proches dans l'espace mathématique.

Trois approches de word embeddings ont été testées et comparées.

6.1 Word2Vec (Skip-gram) — Logan

Contrairement à TF-IDF qui est une représentation statistique (fréquence d'apparition), Word2Vec est une représentation sémantique : il apprend des représentations vectorielles à partir du **contexte local** de chaque mot (par exemple *sad* et *depressed* se trouvent proches dans l'espace vectoriel parce qu'ils apparaissent dans des contextes similaires).

Le mode **Skip-gram** (prédit le contexte à partir d'un mot) est préféré au **CBOW** (prédit un mot depuis son contexte) car notre corpus est **petit et spécialisé** : Skip-gram est plus

performant dans ce cas.

```
model = Word2Vec(
    sentences=all_sentences,
    vector_size=100,      # dimensions des vecteurs
    window=5,            # contexte de 5 mots de chaque cote
    min_count=3,          # ignore les mots apparaissant < 3 fois
    workers=4,            # calcul parallele sur 4 threads
    epochs=10,            # 10 passages complets sur le corpus
    seed=42,              # permet de reproduire le resultat
    sg=1                  # Skip-gram (0 = CBOW)
)
```

Il est important de préciser que le paramètre **epoch** ne doit pas être trop grand, cela augmenterait le risque de **surapprentissage** sur un corpus petit comme le nôtre.

Résultats avec $K = 6$ (patients)

Cluster	Thème	Effectif
0	Dépression	893
1	Problèmes sexuels — santé physique	21
2	Thérapie de couple — anxiété	414
3	Mal-être général	1 084
4	Anxiété — trouble du sommeil	195
5	Traumatisme	88

La répartition est déséquilibrée, mais cela peut être interprété positivement : le cluster 1 isole des problèmes sexuels spécifiques qui auraient été noyés dans un cluster « relations de couple » plus large.

6.2 Sentence Transformer (BERT / all-MiniLM-L6-v2) — Idir

Contrairement à Word2Vec qui produit un vecteur **par mot**, Sentence Transformer produit un vecteur **par phrase entière** en 384 dimensions, via un modèle pré-entraîné sur de larges corpus de langue naturelle.

Résultats avec $K = 8$

Effectif	Thème du cluster	Mots représentatifs
111	Marriage and infidelity	husband, married, relationship, love, wife
86	Seeking therapy and abuse	therapist, counseling, child, therapy, issues
121	Romantic relationships and dating	love, relationship, boyfriend, guy, dating
101	Family and parenting	mom, dad, child, mother, family
95	Anxiety and mental disorder	anxiety, depression, attacks, sleep, panic
105	Social anxiety and communication	thoughts, friends, talking, upset, anger
75	Sexuality and gender identity	sex, girl, love, men, afraid, girls
102	Depression and social life	friends, school, sad, depressed, family

Meilleur résultat de la méthode 3 : clusters de taille homogène (≈ 75 – 121), thèmes distincts et bien interprétables. Certains mots apparaissent dans plusieurs clusters (*love, relationship*) mais le sens varie selon les co-occurents.

6.3 spaCy (embeddings moyennés) — Emin

spaCy calcule un vecteur de phrase en **moyennant les vecteurs des mots** (contrairement aux transformers qui prennent en compte le contexte global).

Résultats avec $K = 5$

Cluster	Mots principaux
0	counseling, therapist, know, end, client, counselor
1	dont, im, like, feel, know, want
2	counseling, really, anything, help, people, something
3	im, ive, like, feel, get, many
4	feel, years, time, im, like, relationship

Résultats insuffisants : clusters 0 et 2 très similaires, plusieurs clusters dominés par des mots peu informatifs.

6.4 Bilan comparatif — Méthode 3

Modèle	Qualité	Points forts	Limites
Sentence Transformer	Très bonne	Contexte global, tailles homogènes	Modèle lourd
Word2Vec (Skip-gram)	Bonne	Granularité thématique fine	Déséquilibre de taille
spaCy	Passable	Rapide, simple	Perte de contexte


Sentence Transformer est la méthode la plus robuste pour ce corpus.

7 Topic Modeling — Méthode 4 : LDA

7.1 Principe

LDA (*Latent Dirichlet Allocation*) est un modèle probabiliste génératif. Contrairement au clustering, LDA produit une **assignation douce** : chaque document reçoit une **distribution de probabilités** sur l'ensemble des topics (et non une assignation exclusive à un seul cluster).

- Chaque **document** est un mélange de plusieurs sujets.
- Chaque **sujet** est défini par une distribution de mots.
- LDA identifie des groupes de mots qui **co-apparaissent** fréquemment.
- Elle associe ensuite à chaque document une **probabilité d'appartenance** à chaque topic.



En sortie, on obtient **deux tableaux de probabilités** : un premier qui définit quels mots caractérisent chaque thème (distribution sur le **vocabulaire**), et un second qui définit dans quelle proportion chaque conversation aborde chaque thème (distribution sur les **thèmes**).

```

N_TOPICS = 6
PASSES = 15

model = LdaModel(
    corpus=corpus,          # corpus au format Bag-of-Words
    id2word=dictionary,     # mapping id -> mot
  
```

```

num_topics=n_topics,      # nombre de topics (a ajuster)
random_state=42,          # reproductibilite
passes=passes              # passes sur le corpus pour la
                           convergence
)

```

Note sur le chevauchement des topics : des mots comme *relationship* ou *boyfriend* apparaissent dans plusieurs topics. Ce n'est pas nécessairement un défaut — LDA tolère cette ambiguïté par conception. Le sens du mot est précisé par les autres mots du topic. Par exemple, *relationship* peut désigner une relation familiale (avec *dad*, *child*) ou amoureuse (avec *boyfriend*, *love*).

7.2 Résultats comparés

Résultats à 6 topics — Logan

Thème	Mots représentatifs
Relations de couple et infidélité	relationship, husband, child, listen, cheat, woman
Relations familiales et soutien social	relationship, people, person, help, dad, family
Relations amoureuses et communication	love, friend, talk, boyfriend, right, therapist
Anxiété et gestion émotionnelle	anxiety, help, talk, friend, feeling, get, try
Détresse émotionnelle et conflits	thought, boyfriend, girl, life, have, stop, cry
Thérapie et problématiques de couple	normal, issue, wife, therapy, walk, couple, self

Résultats relativement bons, bonne distinction entre trois types de relations différentes.

Résultats à 6 topics — Diogo

Thème	Mots représentatifs
Romantic and sexual issues	love, hes, sex, relationship, boyfriend
Mental health and disorders	anxiety, depression, shes, boyfriend, mom
Therapy, communication and coping	school, friends, right, high, live
Relationship trust and family	girlfriend, thinking, hes, thoughts, stop
Intrusive thoughts and past	mother, mom, dad, son, child
Family anger and conflict	therapist, money, phone, relationship, friends

Résultats différents de ceux de Logan mais tout aussi pertinents. On note quelques résidus de mots vides comme *shes* et *hes* (contractions de *she's* et *he's* passées à travers les mailles du filet lors du pré-traitement), mais les différents types de relations sont bien identifiables.

Résultats à 5 topics — Lucas

Thème	Mots représentatifs
Santé mentale, sexualité et famille	sexual, family, self, depression, married, anxiety
Relations amoureuses et questionnements	say, right, boyfriend, think, girlfriend, sex, love
Anxiété, vie quotidienne et thérapie	think, boyfriend, couple, school, anxiety, therapy
Détresse émotionnelle et pensées neg.	bad, think, sex, relationship, afraid, stop, love
Relations de couple et vie familiale	boyfriend, make, counseling, child, life, talk

Beaucoup plus de mots sans signification impactante (*think, say, past*), car Lucas n'a pas ajouté de dictionnaire personnalisé. La réduction à 5 topics a également impacté la diversité des thèmes.

7.3 Évaluation critique

Avantage	Limite
Topics interprétables et cohérents	Choix du nombre de topics difficile
Assignation douce = nuance inter-topics	Sensible au prétraitement
Bien adapté aux textes courts et spécialisés	Résultats variables selon les hyperparamètres
Fondement probabiliste rigoureux	Ne capture pas le contexte long

8 Conclusion comparée des méthodes

Aucune méthode n'est universellement supérieure. Elles sont **complémentaires** et répondent à des besoins différents.

Méthode	Forces	Faiblesses	Usage recommandé
Lexique manuel	Interprétable, contrôlable	Rigide, non-généralisant	Catégorisation ciblée
TF-IDF + K-Means	Rapide, scalable	Ignore le contexte	Exploration initiale
Word2Vec	Similarités sémantiques	Déséquilibre possible	Représentation de mots
Sentence Transformer	Contexte global, homogène	Lourd, moins interprétable	Meilleur clustering
LDA	Assignation douce	Chevauchement de topics	Analyse thématique

Recommandation globale

- Pour **interpréter** les données : **LDA** est le plus lisible et le plus informativement riche.
- Pour **regrouper** les documents : **Sentence Transformer** (BERT) offre la meilleure qualité de clustering.
- Pour une **catégorisation stricte** : le **lexique manuel** reste le plus fiable si le domaine est bien défini.

9 Problèmes rencontrés et questions ouvertes

9.1 Problèmes techniques identifiés

Problème	Description	Impact
Hétérogénéité du nettoyage	Chaque membre a appliqué un pipeline différent	Résultats non directs
Gestion des doublons	Nombre de patients variant de 796 à 995	Biais dans toutes les analyses
Commentaires insuffisants	Manque de documentation dans les notebooks	Difficultés à comprendre les résultats
Choix du nombre de clusters	Méthode du coude peu discriminante après $K = 6$	Difficulté à trouver le bon nombre de clusters
Normalisation des sorties	Formats de résultats différents entre membres	Comparaison manuelle nécessaire

9.2 Questions ouvertes à soumettre à l'encadrante

1. **Standardisation du nettoyage** : nos moyennes de mots varient du simple au quadruple selon le niveau de filtrage. Faut-il fixer une règle commune (mots bruts ou mots porteurs de sens uniquement) pour garantir la comparabilité des résultats ?
2. **Gestion des doublons** : le nombre de patients varie de 796 à 995. Y a-t-il une consigne stricte sur la suppression des messages courts ou des doublons ?
3. **Identification des thérapeutes** : existe-t-il une technique permettant de différencier les patients et thérapeutes entre eux sans identifiant ?
4. **Mots semi-informatifs** : existe-t-il une méthode automatique pour traiter des mots moins significatifs que d'autres mais non considérés comme des stopwords standards ?
5. **Sélection du nombre de clusters** : existe-t-il une méthode plus robuste que la méthode du coude pour déterminer automatiquement k optimal ?