

CAHIER DES CHARGES

Analyse de conversations patient-thérapeute sur la santé mentale

Encadrante : Lynda Tamine-Lechani

19 avril 2026



[Info5.BE-SHS]

Ceci est une version du cahier des charges du projet qui, comme tout cahier des charges qui se respecte, est susceptible d'évoluer en fonction de la demande, des questions et remarques. Des mises à jour seront faites, si besoin.

Mots-clefs

Analyse de texte - Traitement de données - Statistiques

Participants :

Ulysse Chasseigne
Idir Yahiaoui
Bantsoukissa Laure
Cruz Fernandes Diogo
Emin Belkheir
Eso-Y-N Trésor PANA
LARROUX Logan
Yvan Sellier
Victor Blanquart-Blanchet
Lucas Da Silva

Table des matières

I	Descriptif	3
II	Organisation et gouvernance du projet	4
II.1	Organisation des groupes	4
II.2	Définition des rôles	4
II.3	Structure du projet et des documents	5
II.4	Cadence des réunions et Communications	6
III	Méthode	7
III.1	Étape 1 - Exploration du jeu de données	7
III.2	Étape 2 - Analyse et Accès aux conversations	8
III.2.1	Partie 1 : Analyse des sentiments des conversations	8
III.2.2	Partie 2 : Question-réponse sur la santé mentale	8
IV	Livrables	10
V	Ressources	11

I – Descriptif

La santé mentale est un enjeu majeur de la santé publique. Ce projet vise, dans un premier temps, à exploiter le jeu de données pour comprendre les types de conversations et leur structure, puis à analyser les sentiments des échanges afin de détecter les émotions et états psychologiques des patients. Ensuite, il se concentre sur l'accès et le traitement des conversations, en résumant les échanges et en identifiant les schémas linguistiques récurrents. Enfin, il prévoit le développement d'un système question-réponse, capable d'automatiser les interactions et fournir des réponses.

II – Organisation et gouvernance du projet

Compte tenu de l'envergure du projet, une structure hiérarchique est mise en place pour assurer la coordination entre l'exploration commune et les développements spécifiques.

II.1 Organisation des groupes

L'organisation changera deux fois durant ce projet.

Dans un premier temps l'étape 1 se fera de façon individuelle. Chacun devra traiter de son côté ses données afin d'en extraire des informations qui peuvent être par la suite comparées.

Puis dans un second temps, pour la deuxième partie, l'effectif total est divisé en deux groupes distincts. Le groupe 1 sera spécialisé sur "Partie 1 : Analyse des sentiments des conversations" (voir ??) et le groupe 2 sur "Partie 2 : Question-réponse sur la santé mentale" (voir ??).

II.2 Définition des rôles

- **Chef de Projet (Global)** : Il est garant de la cohérence globale. Il supervise les deux groupes, s'assure du respect du diagramme de Gantt, consolide les livrables et assure la communication officielle avec l'encadrante.
- **Chef de groupe (1 par groupe)** : Il gère le planning interne de son groupe, répartit les tâches techniques de la semaine et prépare les points de synchronisation.
- **Membres du groupe** : Chaque membre se verra attribuer des rôles techniques.

Chef de projet : LARROUX Logan

GROUPE 1 (Résumé conversations)

Chef de groupe : Cruz Fernandes Diogo

Ulysse Chasseigne
Cruz Fernandes Diogo
Emin Belkheir
LARROUX Logan
Victor Blanquart-Blanchet

GROUPE 2 (Q/R sur santé mentale)

Chef de groupe : Idir Yahiaoui

Idir Yahiaoui
Bantsoukissa Laure
Eso-Y-N Trésor PANA
Yvan Sellier
Lucas Da Silva

II.3 Structure du projet et des documents

Le projet sera séparé en **deux structures distinctes** afin d'améliorer sa lisibilité.

La première sera hébergée sur **GitHub**. Elle **centralise le travail de l'équipe**, en plus d'un compte rendu détaillé et ciblé sur les méthodes et fonctions utilisées pour chaque étapes du projet.


La seconde sera sur **Google Drive**, plus orientée vers le **suivi de projet**, elle regroupera les avancées de tout le monde (triées de façon hebdomadaire), les résultats obtenues par l'équipe sur plusieurs données demandés dans l'étape ciblée et enfin, un compte rendu sous format **bi-mensuel** résumant les avancée globale, problématiques rencontrés et questions à poser lors des réunion avec la référent.

Ces deux structures devront être respectées pour permettre une organisation claire, stable et efficace du projet.

Structure du projet sur GitHub

```
/
├── bilan_mi_parcours                                # Rapport de mi-parcours
│   ├── bilan-mi-parcours.pdf
│   └── bilan-mi-parcours.tex
├── data
│   └── trains.csv
├── img                                                # Images utilisées dans le projet
│   └── ...
├── notebooks                                         # Travail technique de l'équipe
│   ├── CRUZDiogo
│   ├── EMIN
│   ├── LAURE
│   ├── LOGAN
│   ├── LUCAS
│   ├── TRESOR
│   ├── YVAN
│   └── IDIR
├── comptes_rendus                                    # Explication détaillée des résultats de l'équipe
│   ├── etape1
│   │   ├── compte_rendu_etape1.md
│   │   ├── compte_rendu_etape1.pdf
│   │   └── compte_rendu_etape1.tex
│   └── etape2
│       ├── compte_rendu_etape2.md
│       ├── compte_rendu_etape2.pdf
│       └── compte_rendu_etape2.tex
├── .gitignore
├── README.md
└── BE__Cahier_des_charges.pdf
```

Structure du projet sur Google Drive



II.4 Cadence des réunions et Communications

Pour chaque sous-groupe, une réunion prévue **toutes les semaines** sera organisée pour mettre en revue l'avancement technique, l'identification des points de blocages (bugs, limites des modèles) et définition des objectifs de la semaine suivante. Le chef de groupe compile ces informations et va, par la suite, faire son propre compte-rendu de l'avancée globale.

Ce compte rendu sera ensuite mis à disposition lors des réunions avec la référent, ses réunions se feront au moins **2 fois par mois**. L'objectif est de réunir tout les feed-backs reçus par les deux chefs de groupe et préparer un reporting pour la référente.

Ses compte-rendus, seront accessibles dans le dossier RENDUS_TECH accessible sur le Google Drive de l'équipe.

Février	Avril	Mai
Vendredi 27 (12h30-13h30)	Vendredi 03 (12h15-13h15) Mardi 14 (17h-18h)	Mardi 05 (17h-18h) Mardi 19 (17h-18h)

Ces dates sont susceptibles de changer en fonctions des disponibilités de chacun.

III – Méthode

III.1 Étape 1 - Exploration du jeu de données

Objectif : Comprendre la structure du corpus et identifier les thématiques majeures. Les deux groupes réalisent cette étape en parallèle puis compare leurs résultats.

Le fichier *train.csv* (voir chapitre V) comporte une grande base de données sur deux colonnes : la première est le patient conversant avec le psychologue et la seconde est la réponse du psychologue au patient.

Cette première partie a plusieurs buts :

- **Nettoyage des données (Pré-traitement)** : Suppression de la ponctuation, tokenisation, lemmatisation et retrait des mots vides (*stop-words*).
- **Analyse Statistique** : Création d'un tableau récapitulatif via des scripts Python (Pandas) pour extraire :
 - le nombre de patients uniques
 - le nombre de thérapeutes
 - la distribution des conversations par thérapeute
 - nombre d'échanges moyen par conversation
- **Analyse Lexicale** : génération d'un dictionnaire lexical (n-grams) avec le calcul des fréquences d'apparition des mots par patients, par thérapeutes et par conversations.
- **Modélisation et Extraction de Sujets (*Topic Modeling*)** : Pour cette section, le but est d'utiliser les différentes méthodes et de comparer les résultats entre elles, les méthodes sont :
 - Méthode 1 : Filtrage via un lexique métier défini manuellement (ex : stress, anxiété, sommeil, dépression).
 - Méthode 2 : Vectorisation TF-IDF (Term Frequency-Inverse Document Frequency) suivie d'un clustering (algorithme K-Means) pour regrouper les mots mathématiquement proches.
 - Méthode 3 : Utilisation Word Embedding (Word2Vec ou GloVe) pour capturer le contexte sémantique, couplé à un clustering.
 - Méthode 4 : Entraînement d'un modèle probabiliste LDA (Latent Dirichlet Allocation) pour faire émerger les sujets latents purs.

III.2 Étape 2 - Analyse et Accès aux conversations

III.2.1 Partie 1 : Analyse des sentiments des conversations

Objectif : Implémenter un "catégoriseur" de sentiments des questions-réponses des thérapeutes selon une liste prédéfinie par les thérapeutes (ex. Anxiété, Normal, Dépression, etc.) sur la base uniquement du contenu (mots, phrases, sujets).

Corpus d'entraînement : Un second corpus, distinct du jeu de données principal, est utilisé comme base d'entraînement. Il s'agit du dataset *Sentiment Analysis for Mental Health* (défini comme nom de fichier 'combined_data.csv') disponible sur Kaggle. **Méthodologie** :

Le groupe mettra en œuvre au minimum **deux approches complémentaires** :

- **Méthode supervisée (ex. Naïve Bayes)** : entraînée sur les annotations manuelles du corpus d'entraînement, en utilisant des représentations vectorielles issues de l'étape 1 (TF-IDF, Word2Vec, etc.).
- **Méthode non supervisée (ex. K-Means)** : appliquée sans recours aux étiquettes, afin de comparer les regroupements obtenus avec les catégories définies manuellement.

Le pipeline complet de chaque méthodes comprendra :

1. Un **découpage train/validation/test** du corpus annoté pour garantir une évaluation rigoureuse.
2. Une **évaluation quantitative** à l'aide de métriques standards (précision, rappel, F1-score, matrice de confusion).
3. Un **déploiement sur le dataset principal** (conversation patient-thérapeute) afin de produire des annotations automatiques de sentiments.

Les annotations automatiques générées seront ensuite transmises au Groupes 2 pour être intégrées dans le système question-réponse.

III.2.2 Partie 2 : Question-réponse sur la santé mentale

Objectif : Implémenter un système de question-réponse simple sur le thème de la santé mentale. À une question en langage naturel, le système retourne une liste de réponses candidates ordonnée selon un score de pertinence.

Méthodologie : Le système repose sur l'indexation du corpus de conversations (questions et réponses des thérapeutes). Pour chaque mot du vocabulaire, une association est créée avec l'ensemble des questions et réponses le contenant, formant ainsi un index inversé.

Deux stratégies de recherche de réponse seront implémentées et comparées :

- **Stratégie 1 — Similarité question-question** : identifier les k questions du corpus les plus similaires à la question posée, puis restituer les réponses associées.
- **Stratégie 2 — Similarité question-réponse** : identifier directement les k réponses du corpus les plus similaires sémantiquement à la question posée.

Dans les deux cas, la similarité sera calculée à l'aide de la similarité cosinus appliquée sur les représentations vectorielles des textes : vecteurs TF-IDF, Word2Vec ou BERT.

Évaluation : Les performances des deux stratégies seront mesurées sur un mini-jeu de test de 10 questions-réponses de référence, à l'aide d'une métrique simple de type ratio de bonnes réponses retournées.

Intégration des sentiments : Le système exploitera les annotations automatiques produites par le Groupe 1 pour affiner les réponses retournées : à une question donnée, le système privilégiera les réponses partageant la même annotation de sentiment, assurant ainsi une cohérence thématique et émotionnelle dans les résultats.

IV – Livrables

À l'issue de la période de développement, les éléments suivants seront remis au **responsable de la matière** (Monsieur Vincent DUGAT) et à la **référente du projet** (Madame Lynda TAMINE-LECHANI) :

- **Dépôt du cahier des charges de développement** listant le travail à effectuer ou expliquant les objectifs et la méthode de travail.
Dépôt prévu le 15 mars 2026
- **Bilan de mi-parcours et mise à jour du prévisionnel** est une mise à jour du rapport préliminaire. On listera les objectifs atteints, les succès et difficultés, le travail restant ou perspectives à tester.
Dépôt prévu le 20 avril 2026
- **Dépôt du livrable final** qui comporte deux fichiers :
 - **Le rapport de compte rendu du projet**
 - **La documentation technique de développement**La longueur demandée est d'une dizaine de pages, sans compter la page de garde, dans une police de caractères de taille raisonnable (pas trop grosse, pas trop petite, pas plus de 12 pts), avec des marges de taille raisonnable.
Dépôt prévu le 1 juin 2026
- **Livrable technique** décrivant brièvement les principales techniques, ressources utilisées et les possibles problèmes rencontrés lors de l'avancé.
Dépôt prévu bi-mensuel
- **Compte rendu des étapes** décrivant les résultats obtenu par chacun des membres de l'équipe, les similarité et surtout les différences observées, justifiées de façon claire et concise.
Dépôt prévu à chaque fin d'étape

V – Ressources

- Ensemble de données publié par KAGGLE sur des conversations patient-Thérapeute
- Ensemble de données publié par KAGGLE sur l'analyse de sentiments d'un ensemble d'individus
- Page GitHub de l'équipe