

RAPPORT FINAL

Analyse de conversations patient-thérapeute sur la santé mentale

Cahier des charges, Méthodologie,
Résultats et Analyses

Encadrante : Lynda Tamine-Lechani

Équipe projet :

*Ulysse Chasseigne, Idir Yahiaoui, Bantsoukissa Laure,
Cruz Fernandes Diogo, Emin Belkheir, Ezzo-Y-N Trésor PANA,
Logan Larroux, Yvan Sellier, Victor Blanquart-Blanchet, Lucas Da Silva*

1^{er} juin 2026



[Info5.BE-SHS]

Code : [GitHub du projet](#)

Résumé

Ce rapport présente l'ensemble des travaux réalisés dans le cadre du projet d'analyse de conversations patient-thérapeute sur la santé mentale. Le projet s'articule autour de deux axes principaux : l'analyse exploratoire et la modélisation thématique des conversations (Étape 1), puis le développement d'un système d'analyse de sentiments et de question-réponse (Étape 2).

L'Étape 1 a permis d'explorer en profondeur le corpus de conversations à travers des analyses statistiques, lexicales et quatre méthodes de *topic modeling* (lexique manuel, TF-IDF + K-Means, Word Embeddings et LDA). Les résultats montrent que les thématiques principales tournent autour des relations interpersonnelles, de l'anxiété et de la dépression.

L'Étape 2 a vu le développement parallèle d'un classificateur de sentiments (méthodes supervisées et non supervisées, incluant des approches BERT avancées) et d'un système de question-réponse basé sur la similarité sémantique. Les modèles BERT avec fine-tuning atteignent une accuracy de 83,43%, surpassant significativement les méthodes classiques. Le système question-réponse, utilisant les représentations BERT, obtient un score de similarité de 0,702.

Mots-clefs

Analyse de sentiments - Topic Modeling - BERT - NLP - Santé mentale -
Système question-réponse - Word Embeddings - LDA - TF-IDF

Table des matières

Résumé	1
I Cahier des charges et organisation	6
1 Contexte et objectifs du projet	7
1.1 Présentation générale	7
1.2 Ressources utilisées	7
2 Organisation et gouvernance du projet	8
2.1 Organisation des groupes	8
2.2 Définition des rôles	8
2.2.1 Organisation étape 1 : Exploration du jeu de données	8
2.2.2 Organisation étape 2 : Développement du système d'analyse de sentiments et de question-réponse	9
2.2.3 Étape 2 : Développement du système d'analyse de sentiments et de question-réponse	10
II Étape 1 — Exploration du jeu de données	11
3 Méthodologie générale	12
4 Pré-traitement des données	13
4.1 Nettoyage — Structure générale	13
4.1.1 Tokenisation	13
4.1.2 Suppression de la ponctuation et des mots vides	14
4.1.3 Lemmatisation	14
4.2 Nettoyage — Approches comparées	15
4.2.1 Approche minimaliste (Emin)	15
4.2.2 Approche étendue (Diogo)	15
4.3 Résultats	16
4.3.1 Nombre de patients uniques	16
4.3.2 Nombre de thérapeutes uniques	16
4.3.3 Nombre de mots moyen par patient / thérapeute	17
5 Analyse lexicale et statistique	18
5.1 Mots les plus fréquents	18

5.1.1	Sans filtrage renforcé	18
5.1.2	Avec filtrage renforcé	18
5.1.3	Interprétation	18
5.2	Analyse lexicale — N-grams	19
5.2.1	Définition	19
5.2.2	Choix du n optimal	19
5.2.3	Résultats — Logan, Victor et Lucas	20
6	Topic Modeling	21
6.1	Préambule	21
6.2	Méthode 1 : Lexique personnalisé	22
6.2.1	Principe	22
6.2.2	Approche minimaliste (Trésor)	22
6.2.3	Approche étendue (Diogo)	22
6.2.4	Résultats	23
6.2.5	Évaluation critique	23
6.3	Méthode 2 : TF-IDF + K-Means	24
6.3.1	Principe de TF-IDF	24
6.3.2	Sélection du nombre de clusters (K)	25
6.3.3	Résultats selon K	26
6.3.4	Évaluation critique	28
6.4	Méthode 3 : Word Embeddings	29
6.4.1	Principe du Word Embedding	29
6.4.2	Skip-Gram vs CBOW	29
6.4.3	Word2Vec (Skip-gram) — Logan	30
6.4.4	Sentence Transformer (BERT / all-MiniLM-L6-v2) — Idir	31
6.4.5	spaCy (embeddings moyennés) — Emin	32
6.4.6	Bilan comparatif — Méthode 3	32
6.5	Méthode 4 : LDA (Latent Dirichlet Allocation)	34
6.5.1	Qu'est ce que le LDA ?	34
6.5.2	Résultats à 6 topics — Logan	35
6.5.3	Résultats à 6 topics — Diogo	35
6.5.4	Résultats à 5 topics — Lucas	36
6.5.5	Évaluation critique	36
6.6	Comparaison des méthodes	37
7	Bilan de l'étape 1	38
7.1	Problèmes techniques identifiés	38
7.2	Conclusion globale	39

III	Étape 2 — Analyse et Accès aux conversations	40
8	Vue d'ensemble	41
8.1	Étape 2 — Analyse et Accès aux conversations	41
8.1.1	Module 1 — Classification automatique des sentiments	41
8.1.2	Module 2 — Moteur de question-réponse orienté santé mentale . . .	42
9	Analyse des sentiments — Approches classiques	44
9.1	Contexte et organisation	44
9.1.1	Différence entre méthode supervisée et non-supervisée	44
9.1.2	Métriques d'évaluation utilisées	45
9.2	Résultats par membre	48
9.2.1	Méthode supervisée — Naive Bayes et Logistic Regression	48
9.2.2	Méthode non-supervisée — K-Means (Emin et Victor)	58
9.3	Comparaison globale : supervisé vs. non-supervisé	63
9.4	Décision finale : modèle transmis au Groupe 2	64
10	Analyse des sentiments — Approches BERT	65
10.1	Qu'est-ce que BERT ?	65
10.1.1	Tokenisation WordPiece	65
10.1.2	Points forts	65
10.1.3	Limites	65
10.2	Trois variantes BERT implémentées	66
10.3	Modèle A — BERT sans fine-tuning	66
10.3.1	Principe	66
10.3.2	Résultats — Diogo	66
10.4	Modèle B — BERT avec fine-tuning	66
10.4.1	Principe	66
10.4.2	Résultats — Diogo, Ulysse, Victor, Emin	67
10.5	Modèle C — BERT spécialisé + fine-tuning	67
10.5.1	Principe	67
10.5.2	Modèles disponibles sur Hugging Face	68
10.5.3	Résultats — Logan	68
11	Comparaison globale — Analyse de sentiments	69
11.1	Tableau récapitulatif	69
11.2	Conclusions	69
12	Système Question-Réponse	71
12.1	Indexation inversée	71
12.2	Stratégie 1 : Similarité question-question	71

12.3	Stratégie 2 : Similarité question-réponse	71
12.4	Évaluation des résultats	71
12.4.1	Version 1 — Sans filtrage par thème	72
12.4.2	Version 2 — Avec filtrage par thème (sentiment)	72
12.4.3	Analyse	72
IV	Conclusion générale	73
13	Synthèse des résultats	74
13.1	Étape 1 — Exploration du corpus	74
13.2	Étape 2 — Analyse de sentiments	74
13.3	Étape 2 — Système Question-Réponse	74
14	Perspectives	75
	Références	76

Première partie

Cahier des charges et organisation

Chapitre 1

Contexte et objectifs du projet

1.1 Présentation générale

La santé mentale est un enjeu majeur de la santé publique. Ce projet vise, dans un premier temps, à exploiter le jeu de données pour comprendre les types de conversations et leur structure, puis à analyser les sentiments des échanges afin de détecter les émotions et états psychologiques des patients. Ensuite, il se concentre sur l'accès et le traitement des conversations, en résumant les échanges et en identifiant les schémas linguistiques récurrents. Enfin, il prévoit le développement d'un système question-réponse, capable d'automatiser les interactions et fournir des réponses.

1.2 Ressources utilisées

- [Ensemble de données Kaggle — NLP Mental Health Conversations](#)
- [Ensemble de données Kaggle — Sentiment Analysis for Mental Health](#)
- [Page GitHub de l'équipe](#)

Chapitre 2

Organisation et gouvernance du projet

2.1 Organisation des groupes

L'organisation a évolué en deux phases :

- **Étape 1** : Travail individuel — chaque membre traite ses données de son côté pour en extraire des informations comparables.
- **Étape 2** : Division en deux groupes distincts :
 - **Groupe 1** : Analyse des sentiments des conversations
 - **Groupe 2** : Question-réponse sur la santé mentale

2.2 Définition des rôles

La direction du projet dans sa globalité est assurée par **Logan LARROUX**, qui supervise les deux groupes et garantit la cohérence des livrables. Après constatation de l'ampleur des tâches à réaliser lors de l'étape 1, une bien meilleure organisation a été mise en place pour l'étape 2, avec des chefs de groupe dédiés à chaque axe d'analyse.

2.2.1 Organisation étape 1 : Exploration du jeu de données

Lors de l'étape 1 chaque membre de l'équipe s'est vu assigné les mêmes tâches, afin d'en comparer et de contraster les résultats.

Liste des membres :

- Ulysse Chasseigne
- Idir Yahiaoui
- Bantsoukissa Laure
- Cruz Fernandes Diogo
- Emin Belkheir
- Ezzo-Y-N Trésor PANA
- Logan Larroux
- Yvan Sellier
- Victor Blanquart-Blanchet
- Lucas Da Silva

2.2.2 Organisation étape 2 : Développement du système d'analyse de sentiments et de question-réponse

Comme dit précédemment, l'étape 2 a été divisée en deux groupes distincts, avec des rôles clairement définis pour chaque membre. En plus de cette séparation dans ses deux groupes, nous avons de nouveau séparé les tâches en sous-tâches, afin de mieux répartir le travail et d'assurer une meilleure coordination entre les membres.

Groupe 1 : Analyse des sentiments des conversations

Chef de groupe : Cruz Fernandes Diogo

Sous-groupe 1 Méthode supervisée	Sous-groupe 2 Méthode non-supervisée
Diogo	Victor
Ulysse	Emin
Logan	

Groupe 2 : Question-réponse sur la santé mentale

Chef de groupe : Yahiaoui Idir

Sous-groupe 1 Association Q&A pour chaque mot	Sous-groupe 2 Stratégie 1 Similarité Question-Question	Sous-groupe 3 Stratégie 2 Similarité Question-Réponse
Lucas	Yvan Trésor	Laure Idir

Petite précision

Les étapes de développement de chaque groupe seront détaillées plus loin dans la deuxième et troisième partie du rapport.

2.2.3 Étape 2 : Développement du système d'analyse de sentiments et de question-réponse

Deuxième partie

Étape 1 — Exploration du jeu de données

Chapitre 3

Méthodologie générale

Objectif : Comprendre la structure du corpus et identifier les thématiques majeures.

Le fichier `train.csv` comporte une grande base de données sur deux colonnes : la première est le patient conversant avec le psychologue (Context) et la seconde est la réponse du psychologue au patient (Response).

Cette première partie comporte :

- **Nettoyage des données (Pré-traitement)** : Suppression de la ponctuation, tokenisation, lemmatisation et retrait des mots vides (*stop-words*).
- **Analyse Statistique** : Création d'un tableau récapitulatif via des scripts Python (Pandas).
- **Analyse Lexicale** : Génération d'un dictionnaire lexical (n-grams) avec calcul des fréquences.
- **Modélisation et Extraction de Sujets (*Topic Modeling*)** : Quatre méthodes comparées.




FIGURE 3.1 – Pipeline détaillé de l'étape 1 : Exploration du jeu de données

Chapitre 4

Pré-traitement des données

4.1 Nettoyage — Structure générale

Avant toute analyse, plusieurs étapes de nettoyage ont été appliquées dans l'ordre suivant.

Suppression des cellules vides et des doublons. Les lignes contenant des valeurs nulles dans les colonnes `Context` ou `Response` ont été supprimées, ainsi que les lignes entièrement dupliquées.

Filtrage des textes non-anglais. Le corpus contenait des phrases en espagnol. La bibliothèque `langdetect` a été utilisée pour détecter la langue de chaque ligne et ne conserver que les textes identifiés comme anglais. Cette détection est effectuée au niveau de la phrase entière, ce qui est bien plus fiable qu'une détection mot par mot.

```
from langdetect import detect, LangDetectException

def is_english_text(text):
    try:
        return detect(str(text)) == 'en'
    except LangDetectException:
        return True # texte trop court -> on garde

mask = df['Context'].apply(is_english_text) \
        & df['Response'].apply(is_english_text)
df = df[mask].reset_index(drop=True)
```

Normalisation. Tous les textes ont été passés en minuscules afin d'éviter que *"Toto"* et *"toto"* soient traités comme deux mots distincts. Les espaces insécables (`\xa0`), fréquents dans des données extraites du web, ont également été supprimés.

4.1.1 Tokenisation

La tokenisation consiste à découper chaque phrase en unités élémentaires appelées *tokens*. La bibliothèque `spaCy` (`en_core_web_sm`) a été utilisée pour cette étape, via `nlp.pipe()` afin de traiter les données en batch et réduire le temps de traitement.

4.1.2 Suppression de la ponctuation et des mots vides

Les *stopwords* (mots vides) sont des mots sans réelle signification sémantique (pronoms, ad-
verbes, mots de liaison). spaCy les identifie automatiquement via l'attribut `token.is_stop`.
Les tokens de ponctuation ont été supprimés de la même façon avec `token.is_punct`.

Des mots trop génériques mais non reconnus comme stopwords ont également été filtrés
manuellement, voici deux exemple de listes d'`extra_stopwords` utilisées par Logan et
Lucas :

```
# Exemple - Logan
extra_stopwords = {
    "feel", "like", "want", "know", "time",
    "thing", "good", "need", "year", "think",
    "tell", "say", "come", "go"
}
```

```
# Exemple - Lucas
mots_inutiles = set([
    "i", "me", "my", "myself", "we", "our", "ours", "ourselves",
    # ... [liste complete dans le notebook]
    "there", "back", "even", "every", "years", "told", "going", "
    still"
])
```

4.1.3 Lemmatisation

La lemmatisation transforme chaque mot en sa forme de base ("*running*" → "*run*", "*better*"
→ "*good*"). Cette étape réduit drastiquement le nombre de tokens distincts et regroupe les
formes similaires. Elle permet également de filtrer les URLs, emails et chiffres dans une
seule passe :

```
df["Context_clean"] = [
    [
        token.lemma_
        for token in doc
        if not token.is_stop
        #...et autres filtres (is_punct, is_url, is_email, etc.)
        and token.lemma_ not in extra_stopwords
    ]
    for doc in docs_context
]
```

Remarque importante

`spaCy` lemmatise différemment selon le contexte grammatical. Par exemple, *"feeling"* utilisé comme nom reste tel quel au lieu d'être ramené à *"feel"*. C'est pourquoi *"feel"* a été retiré manuellement des `extra_stopwords` pour éviter les doublons sémantiques.

4.2 Nettoyage — Approches comparées

Puisque ce pipeline n'a pas été imposé, chaque membre a pu appliquer son propre pré-traitement, avec des niveaux de filtrage différents. Prenons l'exemple de deux approches contrastées, celle d'Emin et celle de Diogo.

4.2.1 Approche minimaliste (Emin)

Celle-ci est la plus simple, elle se limite à la suppression des lignes vides et au reset de l'index. Le résultat est un nombre de patients et de thérapeutes plus élevé, mais avec un risque de bruit plus important dans les données.

```
# Suppression des lignes vides
df = df.dropna(how='all')
df = df.dropna(subset=['Context'])
df = df.dropna(subset=['Response'])
df = df.reset_index(drop=True)
```

4.2.2 Approche étendue (Diogo)

Une version beaucoup plus étendue est celle de Diogo, qui inclut un nettoyage plus poussé du texte, ainsi qu'un filtrage pour ne garder que les conversations en anglais.

Cette approche réduit le nombre de patients et de thérapeutes uniques, mais améliore la qualité des données en éliminant les réponses non pertinentes ou dans une langue différente.

Son pipeline est donc le suivant :

- Nettoyage du texte : suppression de la ponctuation, des caractères spéciaux, des espaces multiples, et conversion en minuscules.
- Filtrage linguistique : utilisation de la bibliothèque `langdetect` pour ne conserver que les conversations en anglais.
- Suppression des stop-words : retrait des mots vides courants en anglais pour se concentrer sur les termes significatifs.
- Suppression des doublons : élimination des conversations identiques pour éviter les biais dans les analyses statistiques.

- Réinitialisation de l'index : après les filtrages, l'index est réinitialisé pour une meilleure gestion des données.

Lemmatisation et tokenisation

L'application de la lemmatisation (et de la tokenisation) pour l'analyse du texte a été un débat au sein de l'équipe. La grande majorité de l'équipe a décidé de ne pas l'appliquer lors de l'analyse statistique et lexicale du corpus, afin de conserver les formes originales des mots.

4.3 Résultats

4.3.1 Nombre de patients uniques

Résultat	Nb. Membres	Nom Membres	Méthode
995	8 personnes	Ulysse - Emin - Victor - Laure - Trésor - Yvan - Idir - Lucas	Sans prétraitement
819	1 personne	Logan	Prétraitement + filtre espagnol
796	1 personne	Diogo	Prétraitement + filtre espagnol

4.3.2 Nombre de thérapeutes uniques

Résultat	Nb. Membres	Nom Membres	Méthode
2 479	6 personnes	Emin - Victor - Idir - Laure - Yvan - Lucas	Sans prétraitement
2 472	1 personne	Ulysse	Léger prétraitement
2 409	1 personne	Logan	Prétraitement complet
≥ 12	1 personne	Diogo	Pattern matching

Limite importante

Les valeurs autour de 2 400–2 479 correspondent très probablement au nombre de lignes/réponses dans le fichier, et non au nombre réel de thérapeutes distincts. En l'absence d'identifiant unique (ID), il est impossible de différencier les thérapeutes entre eux avec certitude.

4.3.3 Nombre de mots moyen par patient / thérapeute

Côté patients		Côté thérapeutes	
Membre	Mots moyens	Membre	Mots moyens
Victor	66,86	Emin	177,2
Emin	55,2	Victor	140,2
Idir	24,8	Idir	84,8
Lucas	21,3	Lucas	82,4
Logan	16,3	Logan	60,1

Interprétation

On observe un rapport allant du simple au quadruple selon le niveau de filtrage. Dans chaque cas, **les thérapeutes ont tendance à produire des réponses plus longues que les patients**, ce qui est cohérent avec la nature de leur rôle dans la conversation.




FIGURE 4.1 – Corrélation entre le nombre de mots côté patient et côté thérapeute — Logan

Maintenant que nous avons une idée de la structure générale du corpus, nous allons pouvoir nous pencher plus en détail sur les **thématiques abordées dans les conversations**, à travers une analyse lexicale afin de mieux comprendre les sujets centraux des échanges.

Chapitre 5

Analyse lexicale et statistique

5.1 Mots les plus fréquents

La fréquence des mots les plus utilisés dans les conversations peut révéler les thématiques centrales abordées par les patients et les thérapeutes. Cependant, **il est crucial de filtrer les mots vides** (stop-words) pour éviter que des termes génériques ne dominent l'analyse.

5.1.1 Sans filtrage renforcé

Ulysse, Emin, Victor, Idir, Trésor et Yvan ont appliqué un filtrage minimal, ce qui a permis de conserver des mots très fréquents mais peu informatifs.

Côté patients	Côté thérapeutes	Global
<i>im, feel, dont</i>	<i>feel, may, help, like</i>	<i>feel, like, may</i>

5.1.2 Avec filtrage renforcé

Diogo, Logan, Laure et Lucas eux ont appliqué un filtrage plus poussé, en retirant des mots génériques comme *feel, like, may*, qui sont très fréquents mais peu spécifiques.

Côté patients	Côté thérapeutes	Global
<i>relationship, love, anxiety</i>	<i>relationship, like</i>	<i>relationship, help</i>

5.1.3 Interprétation

- **Sans filtrage renforcé** → expressions émotionnelles brutes des patients (*feel, love*) et posture d'aide des thérapeutes (*may, help, would*).
- **Avec filtrage renforcé** → thématiques explicites : *relationship, anxiety, love* côté patient ; *relationship* côté thérapeute.

Remarque

Ces résultats confirment que le corpus est centré sur les relations interpersonnelles, sujet le plus fréquent, couplé à des états psychologiques comme l'anxiété.

5.2 Analyse lexicale — N-grams

5.2.1 Définition

Un **n-gram** est une séquence de n mots consécutifs dans un texte. Cette approche permet de capturer non seulement les mots isolés, mais aussi les associations de mots fréquentes.

- **Unigram (n=1)** : mots individuels, ex. "*anxiety*", "*depression*".
- **Bigram (n=2)** : paires de mots, ex. "*mental health*", "*feel like*".
- **Trigram (n=3)** : triplets de mots, ex. "*feel like cry*", "*family support system*".
- ainsi de suite...

Dans notre travail, nous allons devoir repérer des formulations récurrentes qui ont du sens :

Type	Exemple	Interprétation
Unigram (n=1)	<i>anxiety</i> (fréq. 342)	Thème dominant
Bigram (n=2)	<i>mental health</i> (fréq. 87)	Expression caractéristique
Trigram (n=3)	<i>feel like cry</i> (fréq. 54)	Patron de détresse

TABLE 5.1 – Exemples de n-grams et leur interprétation

5.2.2 Choix du n optimal

Il n'existe pas de valeur universelle pour n . Deux indicateurs ont été utilisés pour guider ce choix :

- **Fréquence moyenne** : si elle chute sous un seuil de 5, les n-grams sont trop rares pour être statistiquement significatifs.
- **Pourcentage d'hapax** : si plus de 70 % des n-grams n'apparaissent qu'une seule fois, la taille n est trop grande pour le corpus.




FIGURE 5.1 – Graphe de fréquence moyenne et pourcentage d'hapax en fonction de n

On remarque qu'à partir de $n = 1$, la fréquence diminue déjà fortement. Cependant, les bigrams et trigrams restent exploitables car le seuil d'hapax n'est pas dépassé.

5.2.3 Résultats — Logan, Victor et Lucas

Les bigrams et trigrams apportent un contexte nettement plus riche que les unigrams seuls. Ils peuvent permettre par la suite d'identifier des patrons linguistiques et des thèmes récurrents pour le topic modeling mais malheureusement leur fréquence est relativement faible, ce qui rend leur exploitation plus délicate...

Unigram	fréquence	Unigram	fréquence
<i>relationship</i>	486	<i>help</i>	2150
<i>love</i>	431	<i>relationship</i>	1933
<i>friend</i>	369	<i>way</i>	1668

TABLE 5.2 – Trois plus fréquent **unigram** pour les patients (gauche) et thérapeutes (droite)

Bigram	fréquence	Bigram	fréquence
<i>issue address</i>	94	<i>therapist help</i>	160
<i>self esteem</i>	65	<i>ask question</i>	154
<i>month ago</i>	64	<i>mental health</i>	153

TABLE 5.3 – Trois plus fréquent **bigram** pour les patients (gauche) et thérapeutes (droite)

Trigram	fréquence	Trigram	fréquence
<i>history sexual abuse</i>	51	<i>hello thank question</i>	68
<i>low self esteem</i>	50	<i>mental health professional</i>	52
<i>couple therapy session</i>	48	<i>landwehr dbh lpc</i>	51

TABLE 5.4 – Trois plus fréquent **trigram** pour les patients (gauche) et thérapeutes (droite)

Maintenant que nous avons une idée des mots les plus fréquents, nous allons devoir identifier les thématiques majeures abordées dans les conversations. Pour cela, nous allons appliquer différentes méthodes de **topic modeling**, en comparant leurs avantages et limites respectifs.

Chapitre 6

Topic Modeling

6.1 Préambule

Le **topic modeling** est une technique d'extraction de thèmes latents à partir d'un corpus de textes. Il existe plusieurs méthodes pour réaliser cette tâche, chacune avec ses propres avantages et limites. Dans cette section, nous allons présenter quatre approches différentes pour identifier les thématiques majeures dans les conversations de santé mentale, en commençant par une méthode manuelle basée sur un lexique personnalisé, puis en explorant des méthodes plus automatisées et robustes comme TF-IDF, Word2Vec et LDA.

Remarque importante

Chaque membre de l'équipe a appliqué sa propre version de ces méthodes, ce qui nous a permis d'avoir une diversité d'approches et de résultats à comparer. Par question de clareté, nous allons présenter les résultats de chaque méthode de manière synthétique, en présentant les résultats les plus pertinents et en discutant de leurs avantages et limites respectifs.
(voir les notebooks¹ individuels pour les détails de chaque implémentation).

Méthode	Membres
Lexique personnalisé	Diogo, Trésor, Emin, Logan, Victor, Idir, Trésor, Yvan, Lucas
TF-IDF + K-Means	Ulysse, Diogo, Trésor, Emin, Logan, Victor, Idir, Laure, Trésor, Yvan, Lucas
Word2Vec + Clustering	Ulysse, Diogo, Trésor, Emin, Logan, Victor, Idir, Trésor, Yvan, Lucas
LDA (Latent Dirichlet Allocation)	Ulysse, Diogo, Trésor, Emin, Logan, Victor, Idir, Trésor, Yvan, Lucas

TABLE 6.1 – Répartition des méthodes de topic modeling entre les membres de l'équipe

1. [Liens github des notebooks](#)

6.2 Méthode 1 : Lexique personnalisé

6.2.1 Principe

Un dictionnaire thématique est construit **manuellement**, en associant chaque thème de santé mentale à une liste de mots-clés. Chaque question peut être assignée à plusieurs thèmes simultanément (classification multi-label).

Le but de cette première section était de nous introduire le principe de dictionnaire thématique, ainsi que de nous familiariser avec les thématiques récurrentes dans les conversations de santé mentale.

Remarque

Ce filtrage manuel étant bien entendu subjectif, il ne sera pas appliqué dans les méthodes de topic modeling, qui sont plus robustes à ce type de bruit lexical.

Nous allons présenter deux exemples de lexiques, l'un minimaliste (Trésor) et l'autre plus étendu (Diogo). Bien entendu chaque membre de l'équipe a réalisé son propre lexique.

6.2.2 Approche minimaliste (Trésor)

```
lexique = {  
    'Anxiete':    ['anxious', 'anxiety', 'panic', 'fear'],  
    'Depression': ['depress', 'depression', 'sad', 'suicide'],  
    'Relation':   ['relationship', 'husband', 'wife', 'partner']  
}
```

6.2.3 Approche étendue (Diogo)

```
LEXICON = {  
    'Anxiety':    ['anxiety', 'anxious', 'panic', 'worry', '  
        worried', 'nervous',  
        'fear', 'phobia', 'stress', 'stressed', '  
        overthink', 'dread'],  
    # 11 autres thèmes contenant chacun 12 mots...  
}
```

6.2.4 Résultats

Les thèmes apparaissant de façon transversale :

- **Anxiété** (*anxiety, panic, stress*)
- **Dépression** (*depression, sad, hopeless*)
- **Relations** (*relationship, love, partner*) — thème le plus fréquent

6.2.5 Évaluation critique

Avantage	Limite
Très interprétable et explicable	Rigide : ne capte que les mots explicitement listés
Facile à adapter au domaine	Ne gère pas les synonymes non prévus
Résultats stables et reproductibles	Nécessite une expertise métier
Classification multi-label naturelle	Insensible au contexte d'usage d'un mot

Toute l'équipe est en accord avec trois thématiques principales : anxiété, dépression et relations. Or cela ne signifie pas que ses thématiques sont les plus fréquentes, bien au contraire ! D'autres thèmes bien plus spécifique auxquels on ne penserait pas peuvent faire leur apparition. D'où l'intérêt de méthodes plus robustes et moins sujetives que le lexique manuel.

6.3 Méthode 2 : TF-IDF + K-Means

6.3.1 Principe de TF-IDF

Le **TF-IDF** (*Term Frequency — Inverse Document Frequency*) est une méthode de pondération évaluant l'importance d'un mot au sein d'un document par rapport à l'ensemble du corpus. Il combine deux composantes :

- **Term Frequency (TF)** : fréquence d'un terme dans le document.

$$tf_{i,j} = \frac{n_{i,j}}{\sum_k n_{k,j}}$$

où $n_{i,j}$ est le nombre d'occurrences du terme i dans le document j .

- **Inverse Document Frequency (IDF)** : pondération par la rareté du mot dans le corpus.

$$idf(w) = \log\left(\frac{N}{df_t}\right)$$

où N est le nombre total de documents et df_t le nombre de documents contenant le terme t .

Le score final est :

$$w_{i,j} = tf_{i,j} \times \log\left(\frac{N}{df_i}\right)$$

Les vecteurs sont ensuite normalisés par la norme L2 afin que la longueur des documents ne biaise pas les comparaisons.

Grâce au pré-traitement déjà effectué (suppression des stopwords, lemmatisation), l'IDF discrimine mieux les termes et les scores sont plus significatifs.

Vectorisation TF-IDF

On ne peut malheureusement pas utiliser TF-IDF directement sur les textes bruts, il faut d'abord les vectoriser. Vectoriser un texte signifie le transformer en une représentation numérique, pour que par la suite les algorithmes puissent les traiter.

Pour cela, nous allons utiliser la fonction `TfidfVectorizer` de la bibliothèque **scikit-learn**. Cette fonction a de grands avantages, elle permet de :

- lister tous les mots uniques
- définir le score TF
- définir le score IDF
- définir le score final et vecteur L2




FIGURE 6.1 – Exemple d’histogramme des 10 mots les plus importants selon le score TF-IDF (Logan)

Clustering K-Means

Après avoir vectorisé les textes en utilisant TF-IDF, nous obtenons une matrice de taille $N \times M$ (où N est le nombre de documents et M le nombre de mots uniques). Grâce à cette matrice, nous allons pouvoir maintenant regrouper les mots similaires en **clusters**, or nous devons dans un premier temps définir le nombre de clusters K à utiliser. Un des risques est de choisir un K trop petit ou trop grand, ce qui peut conduire à des clusters peu significatifs ou à un sur-apprentissage.

6.3.2 Sélection du nombre de clusters (K)

Plusieurs stratégies explorées :

- Définition manuelle
- Méthode du coude (*elbow method*)
- Équilibrage des tailles

Remarque

Une méthode que nous aurions pu explorer mais que nous n’avons pas fait est la **silhouette score**, qui mesure la cohésion et la séparation des clusters pour différents K . Combiné avec la méthode du coude, cela aurait pu nous aider à trouver un compromis entre la qualité des clusters et leur interprétabilité.

6.3.3 Résultats selon K

$K = 6$ — Clusters déséquilibrés — Logan

La méthode du coude (*elbow method*) a été utilisée pour déterminer le nombre optimal de clusters K . L'inertie diminue fortement jusqu'à $K = 6$, puis la courbe se stabilise.




FIGURE 6.2 – Graphe de la méthode du coude pour déterminer le nombre optimal de clusters K

$K = 6$ a donc été retenu.

Thème identifié	Effectif
Dépression sévère — idées suicidaires	457
Mal-être général — perte de motivation	112
Dépression sévère — fatigue mentale	46
Thérapie de couple — anxiété	223
Traumatisme — abus — maladie grave	1 718
Problèmes familiaux — divorce — identité	139

Résultat peu satisfaisant

Fort déséquilibre de taille (46 vs 1 718), thèmes qui se recoupent. Une des solutions aurait été d'agrandir la plage de K testée, mais cela aurait conduit à des clusters encore plus petits et moins interprétables.

$K = 3$ — Meilleure configuration avec LSA — Diogo

Très petite explication du LSA

La **LSA** (*Latent Semantic Analysis*) est une technique de réduction de dimension appliquée à la matrice TF-IDF. Elle repose sur la **décomposition en valeurs singulières** (SVD) :

$$M = U \cdot \Sigma \cdot V^T$$

où $M \in \mathbb{R}^{d \times n}$ est la matrice terme-document (d termes, n documents), U les vecteurs de termes, Σ la matrice diagonale des valeurs singulières, et V^T les vecteurs de documents dans l'espace latent.

En ne conservant que les k premières composantes ($k \ll d$), on projette les documents dans un espace sémantique réduit avec deux avantages principaux :

- **Réduction du bruit lexical** : des termes synonymes (ex. *sad* et *depressed*) qui co-occurrent dans des contextes similaires se rapprochent dans l'espace réduit.
- **Amélioration du clustering** : K-Means est sensible à la *malédiction de la dimensionnalité* ; réduire la dimension améliore la qualité des clusters.

Dans l'implémentation de Diogo, la LSA est appliquée via `TruncatedSVD` de `scikit-learn` avec 50 composantes, après vectorisation TF-IDF :

```
from sklearn.decomposition import TruncatedSVD
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import Normalizer

svd = TruncatedSVD(n_components=50, random_state=42)
X_lsa = make_pipeline(X)
X_norm = Normalizer().fit_transform(X_lsa) # Normalisation L2
```

La normalisation finale (norme L2) garantit que les distances cosinus restent interprétables après la projection. Comme montré dans les résultats ($K = 3$), l'ajout de la LSA conduit à des clusters plus équilibrés et thématiquement plus distincts par rapport au clustering TF-IDF seul.

Cela nous permet d'obtenir des clusters plus équilibrés et thématiquement plus distincts, couvrant 100 % du corpus.

Topic	Effectif	Part	Mots-clés principaux
Family and relational dynamics	309	38,8 %	friends, family, child, dad, mom, husband
Emotional distress and mental health	284	35,7 %	anxiety, depression, stop, start, school
Romantic relationships and intimacy	203	25,5 %	love, relationship, boyfriend, sex, girl

Même si les résultats sont meilleurs, on observe que les thèmes restent assez larges et se recoupent partiellement (ex. *family* peut apparaître dans les deux premiers clusters).

6.3.4 Évaluation critique

Bien que la méthode TF-IDF + K-Means soit rapide et facile à implémenter, elle présente plusieurs limites :

Avantage	Limite
Méthode rapide et scalable	Sensible au choix de K
Bien documentée et reproductible	Ignore la sémantique contextuelle des mots
Compatible avec LSA pour de meilleurs résultats	Mots traités comme des entités indépendantes

Ses limites peuvent être partiellement atténuées en combinant avec une réduction de dimension (LSA) ou en utilisant des représentations plus riches comme les word embeddings, **ce qui nous amène à la méthode suivante.**

6.4 Méthode 3 : Word Embeddings

6.4.1 Principe du Word Embedding

Le **Word Embedding** (plongement lexical) est une représentation sémantique des mots sous forme de vecteurs de nombres réels. Deux mots de sens proche ont des vecteurs proches dans l'espace mathématique.

Contrairement à TF-IDF qui est une **représentation statistique** (fréquence d'apparition), Word2Vec est une **représentation sémantique** : il apprend ce que le mot signifie en observant les mots qui l'entourent dans le corpus. Ainsi, "*sad*" et "*depressed*" se trouvent proches dans l'espace vectoriel parce qu'ils apparaissent dans des contextes similaires.

6.4.2 Skip-Gram vs CBOW

Word2Vec propose deux architectures :

- **CBOW** (*Continuous Bag of Words*) : prédit le mot central à partir de son contexte. Très rapide sur les grands corpus, mais la moyenne du contexte *lisse le bruit*, ce qui peut effacer des nuances importantes.
- **Skip-Gram** ($sg=1$) : prédit le contexte à partir du mot central. Plus adapté aux **corpus petits et spécialisés** car il génère plus d'exemples d'entraînement par mot, compensant le manque de données.

Remarque

Étant donné que notre corpus est relativement **petit et spécialisé**, le mode **Skip-Gram** est **généralement recommandé**^a pour capturer des relations sémantiques plus fines.

^a. Référence à cette décision : [geeksforgeeks.org](https://www.geeksforgeeks.org/word-embeddings/)

6.4.3 Word2Vec (Skip-gram) — Logan

La version de logan implémente Word2Vec en mode Skip-Gram, avec les hyperparamètres suivants :

- **vector_size=100** : chaque mot est représenté par un vecteur de 100 dimensions, ce qui permet de capturer une sémantique riche tout en restant gérable pour le clustering.
- **window=5** : le contexte de chaque mot est défini comme les 5 mots précédents et les 5 mots suivants, ce qui permet de capturer des relations à la fois locales et globales.
- **min_count=3** : les mots apparaissant moins de 3 fois sont ignorés, ce qui réduit le bruit et améliore la qualité des embeddings.
- **epochs=10** : le modèle est entraîné pendant 10 itérations sur le corpus, ce qui permet d'obtenir des vecteurs stables sans sur-apprentissage.
- **seed=42** : pour assurer la reproductibilité des résultats.
- **sg=1** : pour activer le mode Skip-Gram, qui est plus adapté à notre corpus de taille modérée.

Résultats avec $K = 6$ (patients)

Cluster	Thème	Effectif
0	Dépression	893
1	Problèmes sexuels — santé physique	21
2	Thérapie de couple — anxiété	414
3	Mal-être général	1 084
4	Anxiété — trouble du sommeil	195
5	Traumatisme	88

Le problème que l'on pourrait avoir sur cette méthode est que les clusters sont très déséquilibrés, ce qui rend l'interprétation plus difficile. La prochaine méthode que nous allons présenter, basée sur les **Sentence Transformers**, permet de mieux équilibrer les clusters et d'obtenir des thématiques plus distinctes.

6.4.4 Sentence Transformer (BERT / all-MiniLM-L6-v2) — Idir

Introduction rapide à BERT

BERT (*Bidirectional Encoder Representations from Transformers*) est un modèle de langage pré-entraîné développé par Google en 2018. Contrairement à Word2Vec, qui génère des embeddings statiques pour chaque mot, BERT produit des embeddings contextuels : le vecteur d'un mot dépend donc de la phrase dans laquelle il apparaît.

Remarque

Le modèle BERT, ayant sa partie dédié dans la troisième partie, sera expliqué bien plus en détails à ce moment là.

Résultats avec $K = 8$

Effectif	Thème du cluster	Mots représentatifs
111	Marriage and infidelity	husband, married, relationship, love, wife
86	Seeking therapy and abuse	therapist, counseling, child, therapy, issues
121	Romantic relationships and dating	love, relationship, boyfriend, guy, dating
101	Family and parenting	mom, dad, child, mother, family
95	Anxiety and mental disorder	anxiety, depression, attacks, sleep, panic
105	Social anxiety and communication	thoughts, friends, talking, upset, anger
75	Sexuality and gender identity	sex, girl, love, men, afraid, girls
102	Depression and social life	friends, school, sad, depressed, family

Remarque

Meilleur résultat de la méthode 3 : clusters de taille homogène (≈ 75 – 121), thèmes distincts et bien interprétables.

Les clusters obtenus avec les embeddings de BERT sont plus équilibrés et thématiquement plus distincts que ceux obtenus avec Word2Vec, ce qui confirme l'importance de la contextualisation dans la représentation des textes. Une autre façon est d'obtenir des **embeddings de phrase** est d'utiliser les **embeddings moyennés de spaCy**, mais cela conduit à des résultats moins satisfaisants, comme nous allons le voir dans la section suivante.

6.4.5 spaCy (embeddings moyennés) — Emin

Dans cette approche, les embeddings de chaque mot sont extraits à l'aide de spaCy, puis moyennés pour obtenir une représentation vectorielle de chaque document. Cependant, cette méthode présente plusieurs limites :

- **Perte de contexte** : en moyennant les embeddings de tous les mots, on perd la structure syntaxique et les relations entre les mots, ce qui peut conduire à des représentations moins précises.
- **Mots peu informatifs** : les mots fréquents et peu discriminants (ex. *know*, *like*, *feel*) peuvent dominer la représentation, masquant les thèmes plus spécifiques.
- **Résultats moins cohérents** : les clusters obtenus sont souvent moins thématiquement distincts et plus difficiles à interpréter que ceux obtenus avec des modèles plus avancés comme BERT.

Résultats avec $K = 5$

Cluster	Mots principaux
0	counseling, therapist, know, end, client, counselor
1	dont, im, like, feel, know, want
2	counseling, really, anything, help, people, something
3	im, ive, like, feel, get, many
4	feel, years, time, im, like, relationship

Résultat insatisfaisant

Clusters 0 et 2 très similaires, plusieurs clusters dominés par des mots peu informatifs.

6.4.6 Bilan comparatif — Méthode 3

Modèle	Qualité	Points forts	Limites
Sentence Transformer	Très bonne	Contexte global, tailles homogènes	Modèle lourd
Word2Vec (Skip-gram)	Bonne	Granularité thématique fine	Déséquilibre de taille
spaCy	Passable	Rapide, simple	Perte de contexte

L'équipe entière s'accorde pour dire que les embeddings de BERT (*via Sentence Transformers*) offrent une meilleure qualité de clustering que les embeddings moyennés de spaCy ou les vecteurs Word2Vec, grâce à leur capacité à capturer le contexte et les nuances

sémantiques des textes. Cependant, cette méthode est **plus lourde à entraîner et à utiliser**, ce qui peut être un frein pour des applications en temps réel ou sur des ressources limitées. La dernière méthode que nous allons présenter, basée sur **LDA**, offre une approche différente en se concentrant sur la **modélisation thématique** plutôt que sur la représentation sémantique.

6.5 Méthode 4 : LDA (Latent Dirichlet Allocation)

6.5.1 Qu'est ce que le LDA ?

Le **LDA** (*Latent Dirichlet Allocation*) est un modèle génératif probabiliste permettant de découvrir des sujets latents dans un corpus. C'est une approche bayésienne qui suppose que chaque document est un **mélange de thèmes**, et que chaque thème est une **distribution de mots**.

Contrairement à K-Means où chaque document appartient à un unique cluster, LDA assigne à chaque conversation un mélange de thèmes avec des probabilités. Par exemple :

"I feel sad and anxious" $\rightarrow$ 70 % dépression + 30 % anxiété

LDA produit deux sorties :

1. **Thèmes** $\rightarrow$ **mots** : distribution des mots caractéristiques pour chaque thème.
2. **Documents** $\rightarrow$ **thèmes** : proportion de chaque thème dans chaque conversation.

Dans cette méthode, nous allons utiliser la bibliothèque **gensim** pour implémenter LDA, en utilisant les représentations de documents au format bag-of-words (corpus) et le dictionnaire de mots (id2word). De plus, selon les membres, nous avons défini un nombre de thèmes N_TOPICS et un nombre de passes $PASSES$ pour l'entraînement du modèle.

```
N_TOPICS = 6
PASSES = 15

model = LdaModel(
    corpus=corpus,
    id2word=dictionary,
    num_topics=n_topics,
    random_state=42,
    passes=passes
)
```

FIGURE 6.3 – Exemple d'implémentation de LDA avec la bibliothèque gensim — Logan

6.5.2 Résultats à 6 topics — Logan

Thème	Mots représentatifs
Relations de couple et infidélité	relationship, husband, child, listen, cheat, woman
Relations familiales et soutien social	relationship, people, person, help, dad, family
Relations amoureuses et communication	love, friend, talk, boyfriend, right, therapist
Anxiété et gestion émotionnelle	anxiety, help, talk, friend, feeling, get, try
Détresse émotionnelle et conflits	thought, boyfriend, girl, life, have, stop, cry
Thérapie et problématiques de couple	normal, issue, wife, therapy, walk, couple, self

Interprétation

Sur 6 topics, on retrouve des thèmes cohérents et distincts, couvrant les relations de couple, les relations familiales, l'anxiété, la détresse émotionnelle et la thérapie. Cependant, certains thèmes se recoupent partiellement (ex. *relationship* apparaît dans plusieurs topics), ce qui est une limite de l'approche.

6.5.3 Résultats à 6 topics — Diogo

Thème	Mots représentatifs
Romantic and sexual issues	love, hes, sex, relationship, boyfriend
Mental health and disorders	anxiety, depression, shes, boyfriend, mom
Therapy, communication and coping	school, friends, right, high, live
Relationship trust and family	girlfriend, thinking, hes, thoughts, stop
Intrusive thoughts and past	mother, mom, dad, son, child
Family anger and conflict	therapist, money, phone, relationship, friends

Interprétation

Pour Diogo, les thèmes sont similaires à ceux de Logan, mais avec des nuances différentes. Par exemple, le thème "*Therapy, communication and coping*" regroupe des mots liés à la vie quotidienne et à la gestion de l'anxiété, tandis que "*Relationship trust and family*" met davantage l'accent sur les relations de confiance et les dynamiques familiales.

6.5.4 Résultats à 5 topics — Lucas

Thème	Mots représentatifs
Santé mentale, sexualité et famille	sexual, family, self, depression, married, anxiety
Relations amoureuses et questionnements	say, right, boyfriend, think, girlfriend, sex, love
Anxiété, vie quotidienne et thérapie	think, boyfriend, couple, school, anxiety, therapy
Détresse émotionnelle et pensées nég.	bad, think, sex, relationship, afraid, stop, love
Relations de couple et vie familiale	boyfriend, make, counseling, child, life, talk

Interprétation

Avec 5 topics, les thèmes sont plus larges et moins distincts que dans les configurations à 6 topics. Par exemple, le thème "*Santé mentale, sexualité et famille*" regroupe des concepts très différents, ce qui rend l'interprétation plus difficile.

6.5.5 Évaluation critique

Lors de l'analyse des ses représentations thématiques, nous avons identifié plusieurs avantages et limites de la méthode LDA :

Avantage	Limite
Topics interprétables et cohérents	Choix du nombre de topics difficile
Assignation douce = nuance inter-topics	Sensible au prétraitement
Bien adapté aux textes courts	Résultats variables selon hyperparamètres
Fondement probabiliste rigoureux	Ne capture pas le contexte long

Les résultats obtenues avec LDA sont généralement plus interprétables que ceux obtenus avec les méthodes basées sur les embeddings, car ils fournissent une distribution de mots pour chaque thème. Cependant, le choix du nombre de topics (N_TOPICS) est crucial et peut grandement influencer la qualité des résultats. De plus, **LDA ne capture pas les relations à long terme entre les mots**, ce qui peut limiter sa capacité à identifier des thèmes plus complexes.

Mais alors dans ce cas, quelle méthode est la meilleure ? Nous allons faire une conclusion comparée de toutes les méthodes présentées dans ce chapitre.

6.6 Comparaison des méthodes

Méthode	Forces	Faiblesses	Usage recommandé
Lexique manuel	Interprétable, contrôlable	Rigide, non-généralisant	Catégorisation ciblée
TF-IDF + K-Means	Rapide, scalable	Ignore le contexte	Exploration initiale
Word2Vec	Similarités sémantiques	Déséquilibre possible	Représentation de mots
Sentence Transformer	Contexte global, homogène	Lourd, moins interprétable	Meilleur clustering
LDA	Assignation douce	Chevauchement de topics	Analyse thématique

Recommandation globale

- Pour **interpréter** les données : **LDA** est le plus lisible et le plus informativement riche.
- Pour **regrouper** les documents : **Sentence Transformer** (BERT) offre la meilleure qualité de clustering.
- Pour une **catégorisation stricte** : le **lexique manuel** reste le plus fiable si le domaine est bien défini.

Que peut-on en conclure ? Il n'existe pas de méthode universelle pour l'analyse de texte, et le choix dépend fortement des objectifs spécifiques, de la nature du corpus et des ressources disponibles. Dans notre cas spécifique, la combinaison de plusieurs méthodes (ex. LDA pour l'analyse thématique + Sentence Transformer pour le clustering) pourrait offrir une approche plus complète et nuancée. Cependant, cela nécessite une expertise plus approfondie et une validation rigoureuse pour éviter les biais et les interprétations erronées.

Chapitre 7

Bilan de l'étape 1

7.1 Problèmes techniques identifiés

Lors de l'étape 1, plusieurs problèmes techniques ont été identifiés qui ont impacté la qualité et la comparabilité des résultats entre les membres du groupe.

Problème	Description	Impact
Hétérogénéité du nettoyage	Chaque membre a appliqué un pipeline différent	Résultats non directement comparables
Gestion des doublons	Nombre de patients variant de 796 à 995	Biais dans toutes les statistiques
Commentaires insuffisants	Manque de documentation dans les notebooks	Difficultés à comprendre le code des autres
Choix du nombre de clusters	Méthode du coude peu discriminante après $K = 6$	Difficulté à trouver un K optimal
Normalisation des sorties	Formats de résultats différents entre membres	Comparaison manuelle laborieuse

Ses résultats ont conduit à une revue complète de l'organisation pour la prochaine étape, avec une standardisation des résultats et une meilleure documentation pour faciliter la collaboration.

7.2 Conclusion globale

Cette première étape a permis de comprendre la structure du corpus et d'extraire les thèmes principaux des conversations patient-thérapeute. Le pré-traitement rigoureux (filtrage des langues, lemmatisation, stopwords) a été déterminant pour la qualité des résultats de topic modeling.

Les différentes méthodes explorées (TF-IDF + K-Means, Word2Vec, Sentence Transformer, LDA) ont chacune leurs avantages et limites, et ont permis d'obtenir des perspectives complémentaires sur les thèmes abordés dans les conversations. Cependant, des problèmes techniques (hétérogénéité du nettoyage, gestion des doublons) ainsi que des questions ouvertes (standardisation du nettoyage, identification des thérapeutes) restent à résoudre pour améliorer la qualité et la comparabilité des résultats.

Maintenant que nous avons une bonne compréhension des thèmes présents dans les conversations, nous allons pouvoir passer à l'étape suivante qui consiste à analyser les sentiments exprimés et à implémenter un système de question-réponse sur la santé mentale.

Troisième partie

Étape 2 — Analyse et Accès aux conversations

Chapitre 8

Vue d'ensemble

8.1 Étape 2 — Analyse et Accès aux conversations

Cette seconde étape constitue le cœur applicatif du projet. Elle se divise en **deux modules distincts mais complémentaires**, développés en parallèle par les deux sous-groupes de l'équipe. Le premier module vise à doter le système d'une capacité de reconnaissance automatique des émotions, tandis que le second exploite ces annotations pour construire un moteur de recherche de réponses adaptées au contexte psychologique de l'utilisateur.

8.1.1 Module 1 — Classification automatique des sentiments

Objectif : Attribuer automatiquement une étiquette de sentiment à chaque échange patient-thérapeute, selon une taxonomie clinique de sept catégories (Anxiety, Bipolar, Depression, Normal, Personality disorder, Stress, Suicidal), en se basant exclusivement sur le contenu textuel.

Corpus d'entraînement. Le modèle est entraîné sur le dataset `Combined_Data.csv` (*Sentiment Analysis for Mental Health*, Kaggle), un corpus annoté indépendant du jeu de données principal.

Approches implémentées. Deux méthodes d'apprentissage sont explorées et comparées :

- **Méthodes supervisées** — Naive Bayes, Régression Logistique et LinearSVC exploitent les annotations manuelles pour apprendre une fonction de décision, en s'appuyant sur les représentations vectorielles issues de l'Étape 1 (TF-IDF, Word2Vec).
- **Méthode non supervisée** — L'algorithme K-Means partitionne l'espace des caractéristiques sans recours aux étiquettes ; les clusters obtenus sont ensuite mis en correspondance avec les catégories cliniques.

Pipeline d'évaluation. Chaque méthode suit un protocole standardisé : découpage stratifié en ensembles d'entraînement (60%), de validation (20%) et de test (20%), puis évaluation quantitative via accuracy, précision, rappel, F1-score et matrice de confusion.

Les modèles les plus performants sont déployés sur le corpus principal (`train.csv`) pour annotation automatique.

Transfert inter-modules. Les annotations produites sont transmises au Module 2 sous forme tabulaire (identifiant de conversation, étiquette prédite, score de confiance), permettant un filtrage par cohérence émotionnelle des réponses retournées.

Remarque

Les résultats détaillés des approches classiques sont présentés au Chapitre 9, tandis que les approches avancées basées sur BERT font l'objet du Chapitre 10.

8.1.2 Module 2 — Moteur de question-réponse orienté santé mentale

Objectif : À partir d'une question formulée en langage naturel, retourner les k réponses les plus pertinentes extraites du corpus de conversations thérapeutiques, classées par score de similarité décroissant.

Architecture de l'index. Le système construit un **index inversé** à partir du corpus nettoyé : chaque terme du vocabulaire est associé à l'ensemble des paires question-réponse qui le contiennent, permettant une récupération rapide des conversations candidates.

Stratégies de recherche. Deux approches sont implémentées et comparées :

- **Similarité question-question (Q-Q)** — Identifier les k questions du corpus les plus proches de la requête, puis retourner les réponses associées.
- **Similarité question-réponse (Q-R)** — Rechercher directement les k réponses du corpus maximisant la similarité sémantique avec la question posée.

La similarité est calculée par la **mesure du cosinus** appliquée à trois types de représentations vectorielles couvrant un spectre du lexical au sémantique : TF-IDF, Word2Vec et BERT (all-MiniLM-L6-v2).

Intégration du filtrage par sentiment. Le module exploite les annotations du Module 1 pour restreindre l'espace de recherche aux conversations partageant l'étiquette de sentiment de la question d'entrée. Ce mécanisme de **filtrage par cohérence émotionnelle** assure que les réponses retournées sont non seulement pertinentes lexicalement, mais également adaptées au contexte psychologique de la requête.

Protocole d'évaluation. Les performances sont mesurées sur un jeu de test de 10 paires question-réponse de référence, via la moyenne des similarités cosinus entre réponses prédites et réponses attendues. Les deux versions (avec et sans filtrage par sentiment) sont comparées pour quantifier l'apport des annotations émotionnelles à la qualité des résultats.

Remarque

Les détails du calcul de similarité, l'implémentation, les résultats complets et l'analyse comparative des stratégies de recherche sont présentés au Chapitre 11.




FIGURE 8.1 – Pipeline détaillé de la seconde étape : Analyse et accès aux conversations

Chapitre 9

Analyse des sentiments — Approches classiques

9.1 Contexte et organisation

L'étape 2 a divisé le groupe 1 en deux sous-groupes travaillant en parallèle sur le même jeu de données d'entraînement (`combined_data.csv`, *Sentiment Analysis for Mental Health* sur Kaggle), avec pour objectif commun d'annoter automatiquement le dataset principal `train.csv` en vue de sa transmission au Groupe 2.

Sous-groupe	Méthode	Membres
Supervisé	Naïve Bayes (BoW + TF-IDF) + Logistic Regression (TF-IDF) + LinearSVC (BoW + TF-IDF)	Diogo, Ulysse, Logan
Non-supervisé	K-Means (Word2Vec + TF-IDF)	Emin, Victor

Le pipeline commun aux deux sous-groupes comprend : nettoyage du texte, tokenisation (NLTK + Porter Stemmer), et vectorisation (BoW, TF-IDF, Word2Vec). Le split des données est identique pour les deux : **60 % train / 20 % validation / 20 % test**, avec stratification sur les classes.

9.1.1 Différence entre méthode supervisée et non-supervisée

Une méthode supervisée apprend à partir d'**exemples déjà étiquetés**. Pour chaque entrée, on connaît la bonne réponse pendant l'entraînement ; le modèle apprend donc à associer des entrées à des sorties connues.

Exemple : classer des e-mails en spam / non-spam, prédire un prix, détecter une maladie à partir de symptômes.

Une méthode non-supervisée, quant à elle, apprend à partir de **données non étiquetées**. Il n'existe pas de bonne réponse fournie au préalable ; le but est de découvrir des structures cachées, des groupes ou des patterns dans les données.

Exemple : regrouper des clients en segments, détecter des anomalies, réduire la dimension des données.

En résumé :

- Supervisée → on connaît la réponse attendue.
- Non-supervisée → on ne connaît pas la réponse, on cherche des structures.

9.1.2 Métriques d'évaluation utilisées

Afin de comparer les modèles et sélectionner le meilleur pour annoter `train.csv`, nous distinguons trois catégories de métriques selon leur domaine d'application.

Métriques communes aux deux méthodes

Ces deux métriques s'appliquent aussi bien à la méthode supervisée qu'à la méthode non-supervisée (après association des clusters aux labels pour cette dernière), ce qui en fait les seuls indicateurs permettant une **comparaison directe** entre les deux approches.

Accuracy Pourcentage de sentiments correctement prédits :

$$\text{Accuracy} = \frac{\text{Nb. de bonnes prédictions}}{\text{Nb. total d'exemples}}$$

Matrice de confusion Permet de visualiser les prédictions par rapport aux vraies classes. Les lignes représentent les vraies classes, les colonnes les classes prédites. Elle révèle les erreurs systématiques du modèle : quelles classes sont confondues entre elles, et dans quelle direction.

Métriques propres à la méthode supervisée

Ces métriques nécessitent de connaître les vrais labels pour chaque exemple, ce qui est possible en apprentissage supervisé mais pas directement applicable au clustering non-supervisé.

MSE (Mean Squared Error) Erreur moyenne au carré entre la vraie valeur et la valeur prédite :

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

R² (Coefficient de détermination) Mesure la proportion de variance des données expliquée par le modèle :

$$R^2 = 1 - \frac{\text{Erreur modèle}}{\text{Erreur moyenne}}$$

Attention

MSE et R^2 sont des métriques de régression. Elles supposent qu'il existe un ordre et une distance numérique significative entre les valeurs prédites et les valeurs réelles. Or nos labels sont nominaux (*Depression*, *Anxiety*, *Normal*...) encodés arbitrairement en entiers : la "distance" entre deux classes n'a aucun sens clinique ni mathématique. Ces deux métriques ne sont donc **pas des indicateurs fiables** pour ce problème et ne doivent pas être utilisées comme critères de décision. L'accuracy et le F1-score sont à privilégier.

Precision, Recall et F1-score Ces trois métriques issues du classification report permettent d'évaluer les performances **classe par classe**, ce qui est essentiel ici en raison du fort déséquilibre entre les 7 catégories de sentiments.

- **Precision** — parmi les prédictions positives, combien sont vraiment positives ?

$$\text{Precision} = \frac{TP}{TP + FP}$$

- **Recall** — parmi les vrais positifs, combien ont été retrouvés ?

$$\text{Recall} = \frac{TP}{TP + FN}$$

- **F1-score** — compromis entre precision et recall, particulièrement utile sur des classes déséquilibrées :

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Avec : TP = vrai positif, TN = vrai négatif, FP = faux positif, FN = faux négatif.

Remarque

Pour comparer les méthodes supervisées entre elles (NB vs LR), nous privilégions le **F1-score macro** (moyenne non pondérée sur les classes) plutôt que le F1 *weighted*, afin de ne pas masquer les mauvaises performances sur les classes minoritaires (*Stress*, *Personality disorder*).

Métriques propres à la méthode non-supervisée

Ces métriques sont spécifiques au clustering : elles évaluent la qualité des groupes formés **sans faire référence aux vrais labels** pendant l'entraînement, ce qui les rend non comparables directement avec les métriques supervisées.

Purity globale Mesure la cohérence interne des clusters : pour chaque cluster, on retient uniquement le label majoritaire parmi ses membres.

$$\text{Purity} = \frac{1}{N} \sum_k \max_j |C_k \cap L_j|$$

Avec N le nombre total d'exemples, C_k le cluster k et L_j la classe réelle j .

Remarque

Plus la Purity est proche de 1, meilleur est le regroupement. Attention : si chaque point forme son propre cluster, la purity vaut 1 — cette mesure peut donc être trompeuse si utilisée seule.

ARI (Adjusted Rand Index) Mesure la similarité entre les vrais labels et les clusters trouvés, en corrigeant le score pour tenir compte du hasard. Sa valeur est comprise entre -1 (pire qu'aléatoire) et 1 (clustering parfait). Contrairement à la Purity, l'ARI **pénalise un trop grand nombre de clusters** et les mauvais regroupements, ce qui en fait un indicateur plus robuste.

Tableau récapitulatif

Catégorie	Mesure	Supervisée	Non-supervisée
Communes	Accuracy	Oui	Oui (après mapping)
	Matrice confusion	Oui	Oui
Supervisée uniquement	MSE	Oui	Non
	R ²	Oui	Non
	Precision	Oui	Non
	Recall	Oui	Non
	F1-score	Oui	Non
Non-supervisée uniquement	Purity	Non	Oui
	ARI	Non	Oui

9.2 Résultats par membre

9.2.1 Méthode supervisée — Naive Bayes et Logistic Regression

Qu'est-ce que Naive Bayes ?

Naive Bayes répond à la question : « **Étant donné les mots de ce texte, quelle est la catégorie la plus probable ?** »

C'est un classificateur probabiliste : plutôt que de tracer une frontière entre les classes comme le ferait un SVM, il **calcule une probabilité** pour chaque classe et retourne celle qui est la plus élevée, en s'appuyant sur le théorème de Bayes :

$$P(\text{classe} \mid \text{mots}) \propto P(\text{classe}) \times \prod_i P(\text{mot}_i \mid \text{classe})$$

Le modèle fait une hypothèse simplificatrice : chaque mot est supposé **indépendant** des autres. Cette simplification rend l'algorithme très rapide à entraîner et étonnamment efficace sur les textes malgré son aspect « naïf ».

Qu'est-ce que la Logistic Regression ?

La Régression Logistique répond à la question : « **Étant donné ce vecteur TF-IDF, à quelle classe ce texte appartient-il le plus probablement ?** »

Contrairement à Naive Bayes qui calcule des probabilités indépendamment mot par mot, la Régression Logistique **apprend un poids pour chaque feature** (ici chaque n -gram TF-IDF) et combine ces poids pour produire un score par classe.

	Naive Bayes	Logistic Regression
Hypothèse	Mots indépendants	Aucune hypothèse sur les features
Frontière	Probabiliste naïve	Frontière de décision optimisée
Classes déséquilibrées	Biais vers la classe majoritaire	Géré via <code>class_weight='balanced'</code>
Corrélations entre mots	Ignorées	Prises en compte implicitement

Le paramètre clé de la LR est **C** (inverse de la régularisation) : un **C** petit entraîne une régularisation forte (modèle simple, évite l'overfitting) ; un **C** grand entraîne une régularisation faible (modèle plus complexe, peut overfit).

Qu'est-ce que LinearSVC ?

Le LinearSVC répond à la question : « **Quelle est la frontière optimale qui sépare le mieux les classes ?** »

Contrairement à la Régression Logistique qui estime des probabilités, le LinearSVC cherche un **hyperplan** (une droite en 2D, un plan en 3D, généralisé en N dimensions) qui sépare les classes en **maximisant la marge**, c'est-à-dire la distance entre la frontière et les points les plus proches de chaque classe. Ces points les plus proches sont les **vecteurs de support** : ils sont les seuls à définir la frontière, tous les autres exemples n'ont aucune influence.

La frontière est linéaire, ce qui est parfaitement adapté aux vecteurs TF-IDF déjà en haute dimension. **En haute dimension, les classes sont souvent linéairement séparables même si elles ne le seraient pas en 2D.**

	Naive Bayes	Logistic Regression	LinearSVC
Approche	Probabiliste	Probabiliste	Géométrique
Apprend	$P(\text{classe} \text{mots})$	Poids par feature	Frontière à marge max
Sortie	Probabilité	Probabilité	Score de décision
Déséquilibre	Sensible	Géré via <code>class_weight</code>	Géré via <code>class_weight</code>
Vitesse	Très rapide	Rapide	Très rapide (haute dim.)
Atout principal	Simplicité	Calibration	Marge max → meilleure généralisation

Remarque

LinearSVC est souvent le modèle le plus performant sur des tâches de classification de texte TF-IDF, car il est nativement conçu pour les espaces de haute dimension et les données creuses (*sparse*), ce qui correspond exactement aux vecteurs TF-IDF.

Diogo et Ulysse — Naive Bayes BoW et TF-IDF

Diogo et Ulysse ont produit les résultats de référence pour la méthode supervisée.

Tuning de l'hyperparamètre α (lissage de Laplace) :

- Valeurs testées : [0.001, 0.01, 0.05, 0.1, 0.5, 1.0, 2.0, 5.0]
- Meilleur α BoW : **0.1** (accuracy validation : 0.6606)
- Meilleur α TF-IDF : **0.05** (accuracy validation : 0.6761)

Résultats sur l'ensemble test :

Modèle	Accuracy test
Naive Bayes + BoW	0.6666
Naive Bayes + TF-IDF	0.6875

Classification report (NB + BoW) :

Classe	Precision	Recall	F1-score
Anxiety	0.68	0.73	0.71
Bipolar	0.60	0.76	0.68
Depression	0.57	0.61	0.59
Normal	0.92	0.70	0.80
Personality disorder	0.50	0.56	0.53
Stress	0.52	0.43	0.47
Suicidal	0.60	0.72	0.65

Classification report (NB + TF-IDF) :

Classe	Precision	Recall	F1-score
Anxiety	0.76	0.71	0.73
Bipolar	0.82	0.58	0.68
Depression	0.54	0.77	0.63
Normal	0.90	0.77	0.83
Personality disorder	0.97	0.29	0.45
Stress	0.83	0.27	0.41
Suicidal	0.65	0.60	0.62




FIGURE 9.1 – Matrice de confusion — NB + TF-IDF (gauche) et NB + BoW (droite) (Diogo et Ulysse)

Remarque

TF-IDF est meilleur sur les deux classes les plus représentées (*Normal* et *Depression*), ce qui tire son accuracy globale vers le haut. Mais sur les 5 autres classes, **BoW gagne à chaque fois**, parfois très largement : *Stress* (43 % vs 27 % de recall) ou *Bipolar* (76 % vs 58 % de recall).

Pourquoi ? TF-IDF pénalise les mots fréquents. C'est utile pour séparer *Normal* de *Depression*, mais pour les classes rares (*Stress*, *Personality disorder*), les mots caractéristiques sont précisément des mots fréquents dans le corpus global (*overwhelmed*, *pressure*, *relationship*...). TF-IDF les « dépouille » de leur signal. Le cas de *Personality disorder* est frappant : **precision 0.97 mais recall 0.29** — le modèle est très sûr quand il prédit cette classe, mais il rate 71 % des vrais cas.

Logan — Naive Bayes + Logistic Regression

Logan a produit le notebook de base structurant le travail commun. Sa contribution individuelle principale est l'implémentation d'une **Régression Logistique** (LR + TF-IDF optimisé), identifiée comme « version extra-performante ».

Paramétrage TF-IDF amélioré :

```
tfidf_vectorizer = TfidfVectorizer(
    ngram_range=(1, 3),      # unigrammes, bigrammes et trigrammes
    max_features=50000,      # limite aux 50k features les plus
                             utiles
    sublinear_tf=True,       # log(tf) au lieu de tf
    min_df=2,                # ignore les mots < 2 documents
    max_df=0.95              # ignore les mots > 95% des documents
)
```

Tuning de l'hyperparamètre alpha (Naive Bayes) :

- Valeurs testées : [0.001, 0.005, 0.01, 0.03, 0.05, 0.07, 0.1]
- Meilleur alpha BoW : **0.1** (accuracy : 0.6606)
- Meilleur alpha TF-IDF : **0.07** (accuracy : 0.6816)

Tuning de l'hyperparamètre C (Logistic Regression) :

- Valeurs testées : [0.01, 0.05, 0.1, 0.3, 0.5, 1.0, 3.0, 5.0, 10.0]
- Meilleur C : **3.0** (accuracy validation : 0.7457)

Résultats comparés sur l'ensemble test :

Modèle	Accuracy test
Naive Bayes + BoW	0.6666
Naive Bayes + TF-IDF	0.6927
Logistic Regression + TF-IDF	0.7532

Comparaison F1-score NB + TF-IDF vs LR + TF-IDF :

Classe	F1 NB TF-IDF	F1 LR TF-IDF	Évolution
Anxiety	0.73	0.80	+0.07
Bipolar	0.67	0.79	+0.16
Depression	0.63	0.69	+0.06
Normal	0.85	0.90	+0.15
Personality disorder	0.40	0.66	+0.26
Stress	0.37	0.57	+0.20
Suicidal	0.63	0.64	+0.01




FIGURE 9.2 – Matrice de confusion — NB + BoW (Haut-Gauche) et NB + TF-IDF (Haut-Droite) et LR + TF-IDF (Bas) (Logan)

Remarque

La Logistic Regression améliore le F1-score sur **toutes les classes**, en particulier *Personality disorder* (+0.26) et *Stress* (+0.20) grâce au paramètre `class_weight='balanced'` qui compense le déséquilibre du dataset.

Problème critique

Classe *Suicidal* : sur 2 129 vrais cas *Suicidal*, 1 391 sont correctement classés **mais 529 sont prédits *Depression***. Confondre *Suicidal* avec *Depression* peut avoir des conséquences réelles dans un contexte médical. Ce problème est commun à toutes les approches testées.

Diogo — LinearSVC + BoW et TF-IDF

Après l'implémentation de Naive Bayes et Logistic Regression, Diogo a exploré le **LinearSVC** (*Linear Support Vector Classifier*), une méthode géométriquement très différente des approches probabilistes précédentes.

Tuning de l'hyperparamètre C :

- Valeurs testées : [0.01, 0.1, 1.0]
- Meilleur C BoW : **0.1** (accuracy : 0.7309)
- Meilleur C TF-IDF : **1.0** (accuracy : 0.7386)

Avec seulement 3 valeurs testées, le temps de traitement atteint déjà **8 minutes**. Une stratégie d'optimisation *coarse-to-fine* est envisageable : une *coarse search* sur une large plage (ex. : 0.001, 0.01, 0.1, 1, 10, 100) pour repérer la bonne zone, puis une *fine search* plus précise autour des meilleures valeurs trouvées.

Classification report (LinearSVC + BoW) :

Classe	Precision	Recall	F1-score
Anxiety	0.77	0.73	0.75
Bipolar	0.79	0.73	0.76
Depression	0.71	0.65	0.68
Normal	0.84	0.95	0.89
Personality disorder	0.68	0.59	0.63
Stress	0.52	0.46	0.49
Suicidal	0.63	0.63	0.63




FIGURE 9.3 – Matrice de confusion — LinearSVC + BoW (Diogo)

Classification report (LinearSVC + TF-IDF) :

Classe	Precision	Recall	F1-score
Anxiety	0.81	0.79	0.80
Bipolar	0.86	0.71	0.78
Depression	0.68	0.70	0.69
Normal	0.85	0.94	0.89
Personality disorder	0.86	0.56	0.68
Stress	0.68	0.46	0.55
Suicidal	0.63	0.61	0.62




FIGURE 9.4 – Matrice de confusion — LinearSVC + TF-IDF (Diogo)

Analyse détaillée des confusions :

Modèle	Vrais <i>Suicidal</i>	Vrais <i>Depression</i>
	→ prédits <i>Depression</i>	→ prédits <i>Suicidal</i>
LinearSVC TF-IDF	593	594
LinearSVC BoW	501	645

TF-IDF est légèrement meilleur sur les deux sens de la confusion *Depression/Suicidal*, ce qui est cohérent avec son meilleur F1 global sur ces deux classes.

Modèle	Vrais <i>Personality disorder</i> classés	Prédits <i>Depression</i>
LinearSVC TF-IDF	120/215 → 56 %	51
LinearSVC BoW	126/215 → 59 %	33

Résultat contre-intuitif : BoW retrouve mieux les vrais *Personality disorder* malgré une accuracy globale inférieure. TF-IDF les noie davantage dans *Depression*.

Modèle	Vrais <i>Stress</i> classés	Prédits <i>Depression</i>	Prédits <i>Normal</i>
LinearSVC TF-IDF	235/516 → 46 %	103	81
LinearSVC BoW	238/516 → 46 %	81	86

Les deux modèles sont quasi identiques sur *Stress*, mais BoW disperse moins vers *Normal* et TF-IDF disperse moins vers *Depression*.

Comparaison F1-score entre toutes les méthodes supervisées (vectorisation TF-IDF) :

Classe	NB TF-IDF	LR TF-IDF	LinearSVC TF-IDF	Meilleur
Anxiety	0.73	0.80	0.80	LR et LinearSVC
Bipolar	0.68	0.79	0.78	LR
Depression	0.63	0.69	0.69	LR et LinearSVC
Normal	0.83	0.90	0.89	LR
Personality disorder	0.45	0.66	0.68	LinearSVC
Stress	0.41	0.57	0.55	LR
Suicidal	0.62	0.64	0.62	LR

LinearSVC et LR sont quasi-équivalents sur la majorité des classes : l'écart est souvent de 0.01 à 0.02 de F1, dans la marge de variabilité normale. Le seul point où LinearSVC prend l'avantage est *Personality disorder* (0.68 vs 0.66), la classe la plus difficile du dataset.

NB reste nettement distancé sur toutes les classes minoritaires. Cet écart est structurel : NB suppose l'indépendance des mots, ce qui lui fait rater les signaux contextuels que LR et LinearSVC captent tous les deux.

La confusion *Depression/Suicidal* persiste quel que soit le modèle. Ce n'est donc pas un problème algorithmique mais une limite du dataset, ces deux classes partageant un

vocabulaire très proche.

9.2.2 Méthode non-supervisée — K-Means (Emin et Victor)

Qu'est-ce que K-Means ?

L'algorithme K-Means regroupe les textes en calculant la **proximité mathématique** entre les vecteurs. Il place des centres (centroïdes) de manière aléatoire, puis les déplace itérativement jusqu'à ce que chaque texte soit rattaché au groupe le plus proche, minimisant ainsi l'inertie totale.

Le sous-groupe non-supervisé a comparé deux approches de vectorisation : **TF-IDF** + **SVD** et **Word2Vec**.

Victor — Implémentation Word2Vec

Victor a privilégié l'utilisation de **Word2Vec** pour capturer le sens profond des mots. Contrairement au TF-IDF qui ne fait que compter, Word2Vec comprend que des termes comme *triste* et *déprimé* sont sémantiquement proches.

Sélection de k : le nombre de groupes (entre 2 et 15) a été choisi automatiquement via le **score de silhouette cosinus** sur la validation, avec un plancher à `max(best_k, y_train.nunique())`.




FIGURE 9.5 – Courbes WCSS et silhouette pour la sélection de k (Victor)

Mapping cluster $\rightarrow$ label (vote majoritaire) : pour nommer chaque cluster, on identifie la classe réelle dominante parmi ses membres. En cas de conflit, le cluster de plus haute pureté conserve l'étiquette (stratégie gloutonne).




FIGURE 9.6 – Résultat du mapping et pureté des clusters (Victor)

Victor a corrigé une erreur du template qui tentait de mélanger TF-IDF et Word2Vec dans la cellule de déploiement final, ce qui rendait le pipeline incohérent.

Emin — Comparaison TF-IDF et robustesse du pipeline

Emin a complété l'étude en implémentant le pipeline complet sous **TF-IDF + SVD** pour comparer les deux représentations.

Pourquoi utiliser SVD avec tf-IDF ? Le possible problème que l'on peut avoir ici est que les vecteurs TF-IDF sont très creux (beaucoup de zéros) et en très haute dimension (50 000 features). Cela peut rendre la tâche de clustering plus difficile pour K-Means, qui fonctionne mieux dans des espaces denses et de dimension modérée. En appliquant une réduction de dimensionnalité via SVD (*TruncatedSVD* sous python), on peut compacter l'information essentielle dans un espace plus petit (ex. : 100 dimensions), ce qui facilite le travail de K-Means.




FIGURE 9.7 – Courbes WCSS et silhouette pour la sélection de k (Emin)




FIGURE 9.8 – Résultat du mapping et pureté des clusters (Emin)

Emin a également résolu des conflits de versions entre `gensim` et `scipy` dans l'environnement de travail, et standardisé la cellule de déploiement B.6 pour utiliser le modèle TF-IDF.

Synthèse — Comparaison TF-IDF vs Word2Vec pour K-Means

Critère	K-Means + TF-IDF	K-Means + Word2Vec
Meilleur k retenu	7	7
Accuracy test	0.4636	0.20
Purity globale	0.54	0.51
ARI	0.25	0.13
Besoin de SVD ?	Oui	Non
Dimension de l'espace	100 (après SVD)	100 (natif)
Pureté max cluster	0.85 (<i>Depression</i>)	0.90 (<i>Normal</i>)
Pureté min cluster	0.30 (<i>Personality disorder</i>)	0.30 (<i>Bipolar</i>)




FIGURE 9.9 – Matrice de confusion — K-Means final (TF-IDF vs Word2Vec)

Contra-intuitivement, TF-IDF (46 %) surpasse Word2Vec (20 %). Les catégories cliniques du dataset (*Depression*, *Anxiety*, etc.) se reconnaissent avant tout par un **vocabulaire symptomatique spécifique**, ce que TF-IDF met précisément en avant. Word2Vec, qui regroupe les mots par contexte sémantique large, tend à fusionner *Depression* et *Suicidal* dans les mêmes clusters — le mapping glouton force alors ces gros clusters sur des labels minoritaires, effondrant l’accuracy globale.

Modèle retenu pour le non-supervisé : K-Means + TF-IDF.

Fichier produit : `train_with_sentiments_kmeans.csv`.

9.3 Comparaison globale : supervisé vs. non-supervisé

Critère	NB TF-IDF (supervisé)	K-Means TF-IDF (non-supervisé)
Accuracy test	0.6875	0.4636
Macro avg F1	0.62	—
Weighted avg F1	0.69	—
Voit les labels à l'entraînement ?	Oui	Non
Hyperparamètre clé	alpha = 0.05	k = 7
Fichier annoté	train_with_sentiments.csv	train_with_sentiments_kmeans.csv

L'écart de **+22 points d'accuracy** en faveur du supervisé est cohérent et attendu : le supervisé a accès aux vrais labels pendant l'entraînement, le non-supervisé pas. Les deux méthodes utilisent la même représentation TF-IDF, donc l'écart reflète purement la différence supervisé/non-supervisé.

Les mêmes classes sont difficiles pour les deux approches (*Personality disorder*, *Stress*, confusion *Depression/Suicidal*). Cela pointe vers une **limite des données elles-mêmes** (classes sous-représentées, vocabulaire qui se chevauche) plutôt qu'un problème algorithmique.

9.4 Décision finale : modèle transmis au Groupe 2

→ **Modèle retenu : LogisticRegression + TF-IDF**

Critère	Justification
Accuracy 75,32 %	Meilleure performance absolue parmi tous les modèles testés
Annotations fiables	Les labels transmis au Groupe 2 doivent être les plus corrects possible pour que le filtrage par sentiments soit utile
Modèle léger	LR est rapide à déployer et à sérialiser (.pkl)

Fichier à transmettre au Groupe 2 : `train_with_sentiments.csv`

Colonne d'annotation : `predicted_sentiment`

Classes prédites : Anxiety, Bipolar, Depression, Normal, Personality disorder, Stress, Suicidal

Note pour le Groupe 2 : Il existe toujours une confusion importante entre les classes *Depression* et *Suicidal* (529 vrais *Suicidal* prédits *Depression*), ce qui peut biaiser les analyses de sentiments. Il est recommandé de traiter ces deux classes avec prudence, voire de les regrouper en une seule catégorie « At Risk » pour les besoins du filtrage par sentiments.

Chapitre 10

Analyse des sentiments — Approches BERT

10.1 Qu'est-ce que BERT ?

BERT (*Bidirectional Encoder Representations from Transformers*) est un modèle de langage développé par Google en 2018. Il repose sur l'architecture Transformer et se caractérise par :

- Sa **bidirectionnalité** : lecture du contexte dans les deux directions simultanément.
- Un **pré-entraînement** sur d'énormes corpus (Wikipedia, BooksCorpus) via deux tâches auto-supervisées : MLM (Masked Language Model) et NSP (Next Sentence Prediction).
- Un **fine-tuning** supervisé pour des tâches spécifiques.

10.1.1 Tokenisation WordPiece

```
"unhappiness" -> ["un", "##happi", "##ness"]
```

10.1.2 Points forts

- Représentations contextuelles
- Transfert de connaissances efficace
- Écosystème riche (RoBERTa, DistilBERT, CamemBERT...)

10.1.3 Limites

- Coût computationnel élevé (110M paramètres pour BERT-base)
- Limite de 512 tokens en entrée
- Complexité en $\mathcal{O}(n^2)$ par rapport à la longueur de la séquence

10.2 Trois variantes BERT implémentées

Modèle	Nom court	Description	Membres
A	BERT sans fine-tuning	Extraction de features, poids gelés	Diogo
B	BERT avec fine-tuning	Tous les poids mis à jour sur notre dataset	Diogo, Ulysse, Emin, Victor
C	BERT spécialisé + fine-tuning	Modèle pré-entraîné sur des sentiments puis fine-tuné	Logan

10.3 Modèle A — BERT sans fine-tuning

10.3.1 Principe

Les poids de BERT sont gelés. BERT est utilisé comme extracteur de features, et une régression logistique apprend à partir des vecteurs [CLS] de 768 dimensions.

10.3.2 Résultats — Diogo

Modèle		Accuracy test		
BERT sans fine-tuning		0,7231		
Classe	Precision	Recall	F1-score	
Anxiety	0,73	0,67	0,70	
Bipolar	0,68	0,62	0,65	
Depression	0,64	0,70	0,67	
Normal	0,88	0,93	0,91	
Personality disorder	0,56	0,38	0,45	
Stress	0,52	0,42	0,46	
Suicidal	0,65	0,59	0,62	

10.4 Modèle B — BERT avec fine-tuning

10.4.1 Principe

Tous les poids de BERT sont mis à jour pendant l'entraînement. Une tête de classification (couche **Linear**) est ajoutée en sortie.

Optimiseur : AdamW avec learning rate de 2×10^{-5} .

Scheduler : `get_linear_schedule_with_warmup` pour décroître le learning rate linéairement.

10.4.2 Résultats — Diogo, Ulysse, Victor, Emin

Epoch	Loss moyenne		
1	0,6361		
2	0,3871		
3	0,2705		

Modèle	Accuracy test		
BERT avec fine-tuning	0,8302		

Classe	Precision	Recall	F1-score
Anxiety	0,88	0,89	0,89
Bipolar	0,86	0,85	0,86
Depression	0,78	0,77	0,78
Normal	0,95	0,95	0,95
Personality disorder	0,77	0,68	0,72
Stress	0,73	0,76	0,74
Suicidal	0,72	0,73	0,72

10.5 Modèle C — BERT spécialisé + fine-tuning

10.5.1 Principe

Utilisation d'un modèle déjà fine-tuné sur des tâches d'analyse de sentiments comme point de départ.

10.5.2 Modèles disponibles sur Hugging Face

Identifiant HF	Base	Pré-entraîné sur...	Classes	Points forts
cardiffnlp/twitter-roberta-base-sentiment-latest	RoBERTa	~124M tweets	3	Texte informel
nlptown/bert-base-multilingual-uncased-sentiment	BERT multilingual	Avis produits	5	Multi-langue
siebert/sentiment-roberta-large-english	RoBERTa-large	15 datasets	2	Généralisation
j-hartmann/emotion-english-distilroberta-base	DistilRoBERTa	6 datasets émotions	7	Émotions fines

Modèle retenu : j-hartmann/emotion-english-distilroberta-base, basé sur DistilRoBERTa et pré-entraîné sur 6 datasets d'émotions.

10.5.3 Résultats — Logan

Epoch	Loss moyenne
1	0,6483
2	0,4305
3	0,3156

Modèle	Accuracy test		
BERT spécialisé avec fine-tuning	0,8343		
Classe	Precision	Recall	F1-score
Anxiety	0,87	0,90	0,88
Bipolar	0,87	0,83	0,85
Depression	0,80	0,76	0,78
Normal	0,96	0,95	0,96
Personality disorder	0,69	0,73	0,71
Stress	0,74	0,78	0,76
Suicidal	0,71	0,76	0,73

Chapitre 11

Comparaison globale — Analyse de sentiments

11.1 Tableau récapitulatif

Modèle	Accuracy test	Temps approx.	Remarque
K-Means + W2V	0,20	Quelques minutes	Non supervisé
K-Means + TF-IDF	0,4636	Quelques minutes	Non supervisé
Naive Bayes + BoW	0,6666	Quelques secondes	Supervisé
Naive Bayes + TF-IDF	0,6927	Quelques secondes	Supervisé
LinearSVC + BoW	0,7309	Quelques minutes	Supervisé
Logistic Regression + TF-IDF	0,7532	Quelques secondes	Supervisé
LinearSVC + TF-IDF	0,7586	Quelques minutes	Supervisé
BERT sans fine-tuning (A)	0,7231	Minutes (CPU)	Baseline BERT
BERT avec fine-tuning (B)	0,8302	Heures (GPU)	Fine-tuning complet
BERT spécialisé + FT (C)	0,8343	~30min (GPU)	Meilleur point de départ

11.2 Conclusions

1. **Les modèles BERT surpassent largement les méthodes classiques** : gain d'environ 8 points de pourcentage.
2. **L'apport du fine-tuning est significatif** : amélioration de plus de 10 points d'accuracy (Modèle A vs B).

3. **Le gain du pré-entraînement spécialisé est marginal** : 0,8302 vs 0,8343, le fine-tuning sur notre dataset ayant déjà extrait des représentations efficaces.
4. **Classes difficiles** : Depression et Suicidal restent souvent confondus, même par les modèles avancés. Personality disorder, Stress et Suicidal restent les classes les plus problématiques.

Chapitre 12

Système Question-Réponse

12.1 Indexation inversée

L’indexation inversée associe chaque mot du corpus aux différentes questions et réponses dans lesquelles il apparaît.

Formellement : $\text{mot} \rightarrow \{(\text{question}, \text{réponse})\}$

Un compteur de type **Counter** est utilisé pour comptabiliser les occurrences des mots dans chaque discussion.

12.2 Stratégie 1 : Similarité question-question

Cette approche consiste à retrouver des réponses pertinentes à partir de la similarité entre la question de l’utilisateur et les questions présentes dans le corpus.

Deux versions :

- **Version 1** : recherche sur l’ensemble du corpus
- **Version 2** : recherche limitée aux questions du même thème (filtrage par sentiment)

Vectorisation : TF-IDF, Word2Vec, BERT (all-MiniLM-L6-v2).

Similarité : cosinus, sélection des $k = 5$ questions les plus proches.

12.3 Stratégie 2 : Similarité question-réponse

Cette approche consiste à retrouver directement les réponses les plus pertinentes en se basant sur la similarité entre la question et l’ensemble des réponses du corpus.

Deux versions (avec et sans filtrage par thème).

Mêmes méthodes de vectorisation et de calcul de similarité.

12.4 Évaluation des résultats

Métrique : moyenne des inverses des scores de similarité cosinus sur 10 paires de test.

$$\text{Score} = \frac{1}{N} \sum_{i=1}^N \text{cosine_similarity}(R_{\text{pred},i}, R_{\text{true},i})$$

12.4.1 Version 1 — Sans filtrage par thème

Méthode	TF-IDF	Word2Vec	BERT
Similarité question-question	0,3141	0,4242	0,4627
Similarité question-réponse	0,32	0,53	0,5627

12.4.2 Version 2 — Avec filtrage par thème (sentiment)

Méthode	TF-IDF	Word2Vec	BERT
Similarité question-question	0,4101	0,622	0,67
Similarité question-réponse	0,4101	0,664	0,702

12.4.3 Analyse

- Les méthodes basées sur Word2Vec et BERT offrent de meilleures performances que TF-IDF.
- Le filtrage par thème améliore significativement les résultats (gain de 0,10 à 0,14).
- La stratégie question-réponse surpasse légèrement la stratégie question-question.
- BERT avec filtrage par thème obtient le meilleur score : 0,702.

Quatrième partie

Conclusion générale

Chapitre 13

Synthèse des résultats

13.1 Étape 1 — Exploration du corpus

L’exploration du corpus a révélé que :

- Le corpus est centré sur les **relations interpersonnelles**, l’**anxiété** et la **dépression**.
- Les quatre méthodes de topic modeling sont complémentaires : LDA pour l’interprétation, Sentence Transformer pour le clustering, le lexique manuel pour la catégorisation stricte.
- Les divergences de prétraitement ont un impact significatif sur les résultats, soulignant la nécessité d’une standardisation.

13.2 Étape 2 — Analyse de sentiments

Les résultats montrent une progression claire :

- Méthodes classiques : 66-76% d’accuracy
- BERT sans fine-tuning : 72,31%
- BERT avec fine-tuning : 83,02%
- BERT spécialisé + fine-tuning : 83,43%

Le gain apporté par BERT est considérable, mais les classes difficiles (Personality disorder, Stress, Suicidal) restent problématiques.

13.3 Étape 2 — Système Question-Réponse

Le système de question-réponse performe le mieux avec :

- La stratégie **question-réponse** plutôt que question-question
- Les représentations **BERT** plutôt que TF-IDF ou Word2Vec
- Le **filtrage par sentiment** pour restreindre l’espace de recherche

Meilleur score obtenu : **0,702** (BERT, stratégie question-réponse, avec filtrage).

Chapitre 14

Perspectives

- **Amélioration du prétraitement** : standardiser les pipelines de nettoyage pour garantir la comparabilité des résultats.
- **Augmentation des données** : explorer des techniques de data augmentation pour les classes sous-représentées (Personality disorder, Suicidal).
- **Modèles plus avancés** : tester des modèles plus récents comme RoBERTa-large, DeBERTa, ou des modèles génératifs.
- **Intégration complète** : fusionner le classificateur de sentiments et le système Q/R en un pipeline unifié.
- **Évaluation humaine** : compléter les métriques automatiques par une évaluation qualitative par des experts du domaine.

Références

Papiers de référence

- Thomas Hofmann (2013). *Probabilistic Latent Semantic Analysis*.
<https://arxiv.org/pdf/1301.6705>
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2018). *BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding*.
<https://arxiv.org/pdf/1810.04805>
- Wolf, T. et al. (2020). *Transformers : State-of-the-Art Natural Language Processing*.
<https://arxiv.org/pdf/1910.03771>
- Loshchilov & Hutter (2019). *Pre-Training and Fine-Tuning BERT for the IPU*.
<https://docs.graphcore.ai/projects/bert-training/en/latest/bert.html>

Modèles Hugging Face

- bert-base-uncased
<https://huggingface.co/google-bert/bert-base-uncased>
- cardiffnlp/twitter-roberta-base-sentiment-latest
<https://huggingface.co/cardiffnlp/twitter-roberta-base-sentiment-latest>
- j-hartmann/emotion-english-distilroberta-base
<https://huggingface.co/j-hartmann/emotion-english-distilroberta-base>
- sentence-transformers/all-MiniLM-L6-v2
<https://huggingface.co/sentence-transformers/all-MiniLM-L6-v2>

Données

- Github — Page principal du projet
<https://github.com/cypnet/Analyse-de-conversations-sur-la-sant-mentale>
- Github — Répertoire des notebooks
<https://github.com/cypnet/Analyse-de-conversations-sur-la-sant-mentale/tree/main/notebooks>
- NLP Mental Health Conversations
<https://www.kaggle.com/datasets/thedevastator/nlp-mental-health-conversations>
- Sentiment Analysis for Mental Health
<https://www.kaggle.com/datasets/suchintikasarkar/sentiment-analysis-for-mental-l>

Outils

- Python 3.8+
- Bibliothèques : scikit-learn, transformers, sentence-transformers, pandas, numpy, matplotlib, seaborn
- Environnement : Jupyter Notebook, Google Colab