

COMPTE-RENDU TECHNIQUE

Qestion-réponse sur la santé mentale

Auteur : Yahiaoui Idir

Encadrante : Lynda Tamine-Lechani

Équipe :

*Ulysse Chasseigne, Idir Yahiaoui, Bantsoukissa Laure,
Cruz Fernandes Diogo, Emin Belkheir, Esso-Y-N Trésor PANA,
Logan Larroux, Yvan Sellier, Victor Blanquart-Blanchet, Lucas Da Silva*

5 mai 2026



[Info5.BE-SHS]

Données : [Kaggle](#) — NLP Mental Health Conversations

Code : [GitHub](#)

Table des matières

1	Contexte et organisation	2
2	Détails de l'implémentation	3
2.1	Association mots-questions/réponses	3
2.2	Implémentation du système question-réponse	3
2.2.1	Version similarité entre questions	3
2.2.2	Version similarité entre question et réponses	4
3	Evaluation des résultats	5

1 Contexte et organisation

L'étape 2 a divisé le groupe 2 en deux sous-groupes de deux personnes et un sous-groupe d'une personne travaillant en parallèle sur le même jeu de données d'entraînement (`train.csv` avec pour objectif commun d'implémenter un système question-réponse simple sur la santé mentale.

Sous-groupe	Méthode	Membres
Association mots-questions/réponses	Counter	Lucas
Similarité question-question	Cosine similarity (TF-IDF+Word2Vec+Bert)	Yvan, Trésor
Similarité question-réponse	Cosine similarity (TF-IDF+Word2Vec+Bert)	Idir, Laure

Avant d'entamer l'implémentation des fonctions principales mentionné ci-dessus, on a fixé les données d'entraînement à utiliser *train_unique_e2p2.csv* en supprimant les paires (question,réponse) dupliquées. On a également extrait dix paires du fichier d'entraînement précédent de façon aléatoire afin de les utiliser comme données de test (*test_unique_e2p2.csv*). Ensuite, on a développé un code commun pour nettoyer les données(miniscule,enlever la ponctuation, retirer les stopwords) afin de pouvoir comparer les résultats convenablement en sortie.

2 Détails de l'implémentation

Cette section présente les différentes étapes techniques de l'implémentation du système de question-réponse. Elle décrit les choix effectués ainsi que les méthodes utilisées pour la construction de l'indexation et la réalisation du système question-réponse.

2.1 Association mots-questions/réponses

Dans cette étape, on crée un dictionnaire qui associe pour chaque du corpus une liste de questions et de réponses qui contiennent ce terme.

Concrètement, pour chaque ligne de l'ensemble des données, nous combinons les mots issus de la question et de la réponse et on crée un dictionnaire en utilisant la fonction Counter qui permet de déterminer le nombre d'occurrence de chaque mot dans la discussion.

Pour chaque mot respectant le seuil, nous construisons un dictionnaire. Chaque mot est utilisé comme clé, et est associé à une liste contenant les discussions dans lesquelles il apparaît.

Question :

1. Existe-t-il un nombre minimal d'occurrences pour qu'un mot soit pris en compte dans une discussion ?
2. Ce processus est-il appliqué à l'ensemble des mots du corpus ou uniquement à un mot spécifique donné en entrée ?

2.2 Implémentation du système question-réponse

L'approche question-réponse a été réalisée selon deux méthodes : une basée sur la similarité entre les questions, et une autre basée sur la similarité entre la question et les réponses.

2.2.1 Version similarité entre questions

Dans cette version, les questions du corpus et la question entrée par l'utilisateur sont nettoyées et transformées en vecteurs numériques en utilisant 3 méthodes différentes de vectorisation qui sont TF-IDF, Word2Vec et Bert. Ensuite une mesure de similarité est utilisée pour calculer le degré de proximité entre la question utilisateur et chaque question de l'ensemble de données. Dans notre cas, on a utilisé l'approche *Cosine Similarity*.

Les K (dans notre cas $K = 3$) questions ayant les scores les plus élevés sont alors sélectionnées. Les réponses associées à ces questions sont ensuite récupérées et proposées comme réponses à la question entrée.

2.2.2 Version similarité entre question et réponses

Cette approche consiste à comparer directement la question utilisateur aux réponses présentes dans le corpus afin d'identifier celles qui sont les plus proches sémantiquement. Comme pour la première méthode, les réponses et la question en entrée sont transformées en vecteurs numériques à l'aide de 3 techniques de vectorisation qui sont TF-IDF, Word2Vec et Bert. Une mesure de similarité est utilisée dans cette approche aussi pour calculer le degré de proximité entre la question et chaque réponse du corpus. Dans notre cas, on a utilisé l'approche *Cosine Similarity*. Les K réponses obtenant les scores de similarité les plus élevés sont sélectionnées et proposées comme réponses à la question en entrée.

3 Evaluation des résultats

Afin d'évaluer la qualité du système question-réponse, nous avons utilisé une métrique simple basée sur le ratio de bonnes réponses obtenu sur un ensemble de test.

Pour chaque question du jeu de test, la réponse générée par le système est comparée à la réponse attendue. Une réponse est considérée comme correcte si le score retourné par la fonction *Cosine Similarity* est supérieure à un seuil de 0.5.

Pour évaluer en global chaque méthode, le ratio est calculé selon la formule suivante :

$$Ratio = \frac{\text{Nombre de réponses correctes}}{\text{Nombre total de questions}}$$

Cette méthode d'évaluation nous a permis d'obtenir les résultats suivant :

Sous-groupe	TF-IDF	Word2Vec	Bert
Similarité qestion-question	0	1	0.9
Similarité qestion-réponse	0	1	0.8

Les résultats obtenus montrent que la méthode basée sur TF-IDF n'est pas performante. En effet, cette méthode repose uniquement sur la fréquence des mots et ne prend pas en compte le sens sémantique des phrases. Ainsi, deux phrases ayant des significations similaires mais utilisant un vocabulaire différent peuvent être considérées comme peu proches par le modèle TF-IDF. Cela explique les performances faibles observées dans certains cas.

En revanche, les approches basées sur Word2Vec et BERT offrent de meilleurs résultats. Ces méthodes permettent de représenter les textes dans un espace vectoriel où le sens est mieux capturé.