

COMPTE-RENDU TECHNIQUE

Qestion-réponse sur la santé mentale

Auteur : Yahiaoui Idir

Encadrante : Lynda Tamine-Lechani

Équipe :

*Ulysse Chasseigne, Idir Yahiaoui, Bantsoukissa Laure,
Cruz Fernandes Diogo, Emin Belkheir, Esso-Y-N Trésor PANA,
Logan Larroux, Yvan Sellier, Victor Blanquart-Blanchet, Lucas Da Silva*

31 mai 2026



[Info5.BE-SHS]

Données : [Kaggle](#) — NLP Mental Health Conversations

Code : [GitHub](#)

Table des matières

1	Introduction	2
2	Détails de l'implémentation	3
2.1	Indexation inversée	3
2.2	Implémentation du système question-réponse	4
2.2.1	Version similarité entre questions	4
2.2.2	Version similarité entre question et réponses	5
3	Evaluation des résultats	6

1 Introduction

Dans cette partie du projet, nous avons développé un système de questions réponses basé sur des techniques de traitement automatique du langage naturel(NLP). L'objectif principal est de concevoir un modèle capable de retrouver automatiquement les réponses les plus pertinentes à partir d'une question donnée.

Dans le cadre de ce travail, le groupe a été réparti en plusieurs sous-groupes travaillant en parallèle sur le même jeu de données. Chaque sous-groupe était chargé d'implémenter une partie spécifique du système de question-réponse, notamment l'indexation inverse ainsi que les approches de similarité question-question et question-réponse.

Le travail a été réparti entre les membres du groupe. Le tableau suivant présente l'organisation des tâches :

Sous-groupe	Méthode	Membres
Association mots-questions/réponses	Counter	Lucas
Similarité question-question	Cosine similarity (TF-IDF+Word2Vec+Bert)	Yvan, Trésor
Similarité question-réponse	Cosine similarity (TF-IDF+Word2Vec+Bert)	Idir, Laure

Avant l'implémentation des fonctions principales, nous avons fixé le jeu de données utilisé (*train_unique_e2p2.csv*) en supprimant les doublons de paires (question, réponse). Nous avons également constitué un ensemble de test en sélectionnant aléatoirement dix paires issues du jeu de données (*test_unique_e2p2.csv*). Enfin, un module commun de prétraitement a été développé afin de nettoyer les données (mise en minuscule, suppression de la ponctuation et des stopwords), garantissant ainsi une comparaison cohérente des résultats.

2 Détails de l'implémentation

Cette section présente les différentes étapes techniques de l'implémentation du système de question-réponse. Elle décrit les choix méthodologiques ainsi que les approches utilisées pour la construction de l'indexation et la mise en place des différentes méthodes de recherche de réponses. Les étapes sont ensuite détaillées dans les sous-sections suivantes.

2.1 Indexation inversée

L'indexation inversée est une structure de données permettant d'associer chaque mot du corpus aux différentes questions et réponses dans lesquelles il apparaît.

Sur le plan technique, le processus commence par le prétraitement de chaque question et réponse. Chaque texte est normalisé en minuscules, puis la ponctuation est supprimée et les mots vides (stopwords) sont retirés. Les textes sont ensuite tokenisés afin d'obtenir une liste de mots exploitables.

Pour chaque paire (question, réponse), les tokens issus des deux éléments sont combinés afin de former un ensemble unique de mots représentatifs de la discussion. Ensuite, un dictionnaire Python est utilisé pour construire l'index inversé. Les clés de ce dictionnaire correspondent aux mots du corpus, tandis que les valeurs sont des listes contenant les textes associés.

Un compteur de type `Counter` est utilisé afin de comptabiliser les occurrences des mots dans chaque discussion.

Formellement, la structure obtenue peut être représentée comme suit :

$$mot \rightarrow \{(question, réponse)\}$$

Cette représentation permet, pour un mot donné, d'accéder directement à l'ensemble des discussions dans lesquelles il apparaît, ce qui améliore considérablement l'efficacité des étapes de recherche et de similarité dans le système de question-réponse.

2.2 Implémentation du système question-réponse

Le système de question-réponse a été implémenté selon deux approches : une première basée sur la similarité entre questions, et une seconde reposant sur la comparaison directe entre la question et l'ensemble des réponses du corpus.

2.2.1 Version similarité entre questions

Cette approche consiste à retrouver des réponses pertinentes à partir de la similarité entre la question de l'utilisateur et les questions présentes dans le corpus. L'hypothèse principale est que des questions sémantiquement proches doivent partager des réponses similaires.

Dans notre système, deux versions ont été développées. La première repose sur une recherche de similarité appliquée à l'ensemble du corpus, tandis que la seconde limite cette recherche aux questions appartenant au même thème que la question en entrée.

Dans la première version, chaque question est transformée en vecteur à l'aide de trois méthodes de vectorisation : TF-IDF, Word2Vec et BERT (all-MiniLM-L6-v2). La question utilisateur ainsi que l'ensemble des questions du corpus sont représentées dans le même espace vectoriel. TF-IDF capture principalement une similarité lexicale basée sur la fréquence des mots, Word2Vec permet d'obtenir une représentation sémantique via la moyenne des vecteurs de mots, et BERT fournit des embeddings contextuels plus riches permettant de mieux capturer le sens global des questions.

Une fois ces représentations obtenues, la similarité cosinus est calculée entre la question utilisateur et toutes les questions du corpus. Les scores sont ensuite triés afin de sélectionner les k questions les plus proches ($k = 5$). Les réponses associées à ces questions sont finalement récupérées et retournées comme résultats du système.

Dans la seconde version, la même méthode de vectorisation et de calcul de similarité est conservée, mais appliquée uniquement à un sous-ensemble du corpus composé des questions partageant le même thème que la question en entrée. Cette restriction permet de réduire l'espace de recherche et de favoriser des résultats plus cohérents sémantiquement en évitant de comparer la question à des thématiques non pertinentes.

2.2.2 Version similarité entre question et réponses

Cette approche consiste à retrouver directement les réponses les plus pertinentes en se basant sur la similarité entre la question de l'utilisateur et l'ensemble des réponses présentes dans le corpus. L'idée principale est qu'une réponse pertinente doit être sémantiquement proche de la question posée.

Dans notre système, deux versions ont été développées. La première repose sur une recherche de similarité appliquée à l'ensemble des réponses du corpus, tandis que la seconde limite cette recherche aux réponses appartenant au même thème que la question en entrée.

Dans la première version, chaque réponse est transformée en vecteur à l'aide de trois méthodes de vectorisation : TF-IDF, Word2Vec et BERT (all-MiniLM-L6-v2). La question utilisateur ainsi que l'ensemble des réponses du corpus sont représentées dans le même espace vectoriel. TF-IDF permet de capturer une similarité lexicale basée sur la fréquence des mots, Word2Vec fournit une représentation sémantique en moyennant les vecteurs des mots composant la réponse, et BERT génère des embeddings contextuels plus riches permettant de mieux représenter le sens global des phrases.

Une fois ces représentations obtenues, la similarité cosinus est calculée entre la question utilisateur et toutes les réponses du corpus. Les scores sont ensuite triés afin de sélectionner les k réponses les plus proches ($k = 5$), qui sont ensuite retournées comme résultats du système.

Dans la seconde version, la même méthode de vectorisation et de calcul de similarité est conservée, mais appliquée uniquement à un sous-ensemble des réponses appartenant au même thème que la question utilisateur. Cette restriction permet de réduire l'espace de recherche et d'améliorer la pertinence des résultats en évitant des réponses issues de thématiques non pertinentes.

3 Evaluation des résultats

Afin d'évaluer les performances du système de question-réponse, nous avons réalisé des tests sur un ensemble de données de test composé de 10 paires (question, réponse) extraites du corpus.

L'objectif de cette évaluation est de mesurer la capacité des différents modèles à retrouver les réponses pertinentes en fonction d'une question donnée.

Dans notre implémentation, nous avons utilisé la similarité cosinus afin de mesurer la proximité entre la réponse prédite et la réponse attendue. Le score obtenu varie entre 0 et 1, où une valeur proche de 1 indique une forte similarité sémantique.

Afin d'obtenir une mesure globale de performance, nous avons calculé la moyenne des inverses des scores de similarité obtenus sur l'ensemble du jeu de test. Cette approche permet de pénaliser davantage les réponses peu similaires à la réponse attendue.

$$Score = \frac{1}{N} \sum_{i=1}^N \text{cosine_similarity}(R_i^{pred}, R_i^{true})$$

Bien que cette méthode s'inspire du principe du MRR (Mean Reciprocal Rank), elle repose ici directement sur les scores de similarité et non sur un classement explicite des réponses.

Dans ce contexte, un score proche de 1 indique une bonne performance du modèle, car cela signifie que la similarité entre les réponses est élevée.

Pour la première version de cette méthode, on a obtenu les résultats suivant :

Méthode	TF-IDF	Word2Vec	BERT
Similarité question-question	0.3141	0.4242	0.4627
Similarité question-réponse	0.32	0.53	0.5627

Pour la seconde version de cette méthode, on a trouvé les résultats suivant :

Méthode	TF-IDF	Word2Vec	BERT
Similarité question-question	0.4101	0.622	0.67
Similarité question-réponse	0.4101	0.664	0.702

Les résultats obtenus montrent que les méthodes basées sur Word2Vec et BERT offrent de meilleures performances que TF-IDF, ce dernier étant limité à une similarité lexicale et ne prenant pas en compte le sens global des phrases.