

COMPTE-RENDU TECHNIQUE

Qestion-réponse sur la santé mentale

Auteur : Yahiaoui Idir

Encadrante : Lynda Tamine-Lechani

Équipe :

*Ulysse Chasseigne, Idir Yahiaoui, Bantsoukissa Laure,
Cruz Fernandes Diogo, Emin Belkheir, Esso-Y-N Trésor PANA,
Logan Larroux, Yvan Sellier, Victor Blanquart-Blanchet, Lucas Da Silva*

11 mai 2026



[Info5.BE-SHS]

Données : [Kaggle](#) — NLP Mental Health Conversations

Code : [GitHub](#)

Table des matières

1	Introduction	2
2	Détails de l'implémentation	3
2.1	Indexation inversée	3
2.2	Implémentation du système question-réponse	4
2.2.1	Version similarité entre questions	4
2.2.2	Version similarité entre question et réponses	5
3	Evaluation des résultats	6

1 Introduction

Dans cette partie du projet, nous avons développé un système de questions réponses basé sur des techniques de traitement automatique du langage naturel(NLP). L'objectif principal est de concevoir un modèle capable de retrouver automatiquement les réponses les plus pertinentes à partir d'une question donnée.

Dans le cadre de ce travail, le groupe a été réparti en plusieurs sous-groupes travaillant en parallèle sur le même jeu de données. Chaque sous-groupe était chargé d'implémenter une partie spécifique du système de question-réponse, notamment l'indexation inverse ainsi que les approches de similarité question-question et question-réponse.

Le travail a été réparti entre les membres du groupe. Le tableau suivant présente l'organisation des tâches :

Sous-groupe	Méthode	Membres
Association mots-questions/réponses	Counter	Lucas
Similarité question-question	Cosine similarity (TF-IDF+Word2Vec+Bert)	Yvan, Trésor
Similarité question-réponse	Cosine similarity (TF-IDF+Word2Vec+Bert)	Idir, Laure

Avant l'implémentation des fonctions principales, nous avons fixé le jeu de données utilisé (*train_unique_e2p2.csv*) en supprimant les doublons de paires (question, réponse). Nous avons également constitué un ensemble de test en sélectionnant aléatoirement dix paires issues du jeu de données (*test_unique_e2p2.csv*). Enfin, un module commun de prétraitement a été développé afin de nettoyer les données (mise en minuscule, suppression de la ponctuation et des stopwords), garantissant ainsi une comparaison cohérente des résultats.

2 Détails de l'implémentation

Cette section présente les différentes étapes techniques de l'implémentation du système de question-réponse. Elle décrit les choix méthodologiques ainsi que les approches utilisées pour la construction de l'indexation et la mise en place des différentes méthodes de recherche de réponses. Les étapes sont ensuite détaillées dans les sous-sections suivantes.

2.1 Indexation inversée

L'indexation inversée est une structure de données permettant d'associer chaque mot du corpus aux différentes questions et réponses dans lesquelles il apparaît.

Sur le plan technique, le processus commence par le prétraitement de chaque question et réponse. Chaque texte est normalisé en minuscules, puis la ponctuation est supprimée et les mots vides (stopwords) sont retirés. Les textes sont ensuite tokenisés afin d'obtenir une liste de mots exploitables.

Pour chaque paire (question, réponse), les tokens issus des deux éléments sont combinés afin de former un ensemble unique de mots représentatifs de la discussion. Ensuite, un dictionnaire Python est utilisé pour construire l'index inversé. Les clés de ce dictionnaire correspondent aux mots du corpus, tandis que les valeurs sont des listes contenant les textes associés.

Un compteur de type `Counter` est utilisé afin de comptabiliser les occurrences des mots dans chaque discussion.

Formellement, la structure obtenue peut être représentée comme suit :

$$mot \rightarrow \{(question, réponse)\}$$

Cette représentation permet, pour un mot donné, d'accéder directement à l'ensemble des discussions dans lesquelles il apparaît, ce qui améliore considérablement l'efficacité des étapes de recherche et de similarité dans le système de question-réponse.

2.2 Implémentation du système question-réponse

Le système de question-réponse a été implémenté selon deux approches : une première basée sur la similarité entre questions, et une seconde reposant sur la comparaison directe entre la question et l'ensemble des réponses du corpus.

2.2.1 Version similarité entre questions

Cette approche consiste à retrouver les réponses pertinentes en se basant sur la similarité entre la question utilisateur et les questions présentes dans le corpus. L'idée principale est que deux questions similaires sur le plan sémantique doivent partager des réponses proches.

Cette étape est implémentée selon trois méthodes de vectorisation : TF-IDF, Word2Vec et BERT.

Dans les trois cas, la question en entrée ainsi que l'ensemble des questions du corpus sont transformées en représentations vectorielles.

Pour TF-IDF, chaque question est représentée sous forme d'un vecteur sparse basé sur l'importance statistique des mots dans le corpus. Cette méthode permet de capturer principalement une similarité lexicale.

Pour Word2Vec, les mots sont représentés par des vecteurs denses appris à partir de leur contexte. La représentation d'une question est obtenue la moyenne des vecteurs des mots qui la composent, ce qui permet de capturer une similarité sémantique.

Enfin, BERT génère des représentations contextuelles des phrases à l'aide d'un modèle de langage pré-entraîné(all-MiniLM-L6-v2), permettant de mieux capturer le sens global des questions.

Une fois les représentations vectorielles obtenues pour la question utilisateur et les questions du corpus, la similarité cosinus est calculée entre elles. Les scores obtenus sont ensuite triés afin d'extraire les k questions les plus proches($k=5$).

Les réponses associées à ces questions sont finalement récupérées et retournées comme résultats du système.

2.2.2 Version similarité entre question et réponses

Cette approche consiste à retrouver directement les réponses les plus pertinentes en se basant sur la similarité entre la question utilisateur et l'ensemble des réponses présentes dans le corpus. L'idée principale est qu'une réponse pertinente doit être sémantiquement proche de la question posée.

Cette étape est implémentée selon trois méthodes de vectorisation : TF-IDF, Word2Vec et BERT.

Dans les trois cas, la question en entrée ainsi que l'ensemble des réponses du corpus sont transformées en représentations vectorielles.

Pour TF-IDF, chaque réponse est représentée sous forme d'un vecteur sparse basé sur l'importance statistique des mots dans le corpus. Cette méthode permet principalement de capturer une similarité lexicale entre la question et les réponses.

Pour Word2Vec, les mots sont représentés par des vecteurs denses appris à partir de leur contexte. La représentation d'une réponse est obtenue en calculant la moyenne des vecteurs des mots qui la composent, ce qui permet de capturer une similarité sémantique plus fine.

Enfin, BERT génère des représentations contextuelles des phrases à l'aide d'un modèle de langage pré-entraîné (all-MiniLM-L6-v2), permettant de mieux capturer le sens global des réponses.

Une fois les représentations vectorielles obtenues pour la question utilisateur et l'ensemble des réponses du corpus, la similarité cosinus est calculée entre elles. Les scores obtenus sont ensuite triés afin d'extraire les k réponses les plus proches ($k=5$).

Les réponses ainsi sélectionnées sont directement retournées comme résultats du système.

3 Evaluation des résultats

Afin d'évaluer les performances du système de question-réponse, nous avons réalisé des tests sur un ensemble de données de test composé de 10 paires (question, réponse) extraites du corpus.

L'objectif de cette évaluation est de mesurer la capacité des différents modèles à retrouver les réponses pertinentes en fonction d'une question donnée.

Dans notre implémentation, nous avons utilisé la similarité cosinus afin de mesurer la proximité entre la réponse prédite et la réponse attendue. Le score obtenu varie entre 0 et 1, où une valeur proche de 1 indique une forte similarité sémantique.

Afin d'obtenir une mesure globale de performance, nous avons calculé la moyenne des inverses des scores de similarité obtenus sur l'ensemble du jeu de test. Cette approche permet de pénaliser davantage les réponses peu similaires à la réponse attendue.

$$Score = \frac{1}{N} \sum_{i=1}^N \frac{1}{\text{cosine_similarity}(R_i^{pred}, R_i^{true})}$$

Bien que cette méthode s'inspire du principe du MRR (Mean Reciprocal Rank), elle repose ici directement sur les scores de similarité et non sur un classement explicite des réponses.

Dans ce contexte, un score proche de 1 indique une bonne performance du modèle, car cela signifie que la similarité entre les réponses est élevée. À l'inverse, un score élevé traduit une faible similarité entre les réponses comparées.

Cette méthode nous les résultats suivant :

Méthode	TF-IDF	Word2Vec	BERT
Similarité question-question	7.3141	4.5242	2.7627
Similarité gestion-réponse	7.3141	4.5242	2.7627

Les résultats obtenus montrent que les méthodes basées sur Word2Vec et BERT offrent de meilleures performances que TF-IDF, ce dernier étant limité à une similarité lexicale et ne prenant pas en compte le sens global des phrases.